

# FINAL PROJECT: PERBANDINGAN KINERJA MODEL LINIER ARIMA DAN MODEL NON- LINIER LSTM DALAM PERAMALAN HARGA SAHAM PANIN SEKURITAS TBK

Proposed by



Bramayudha Erlangga P  
5003221084



Fairuz Afghan  
5003221086

# Overview: Konten Materi

---

x



## Overview

- Konten Materi



## Bab 1

- Latar Belakang
- Rumusan Masalah & Tujuan
- Manfaat



## Bab 2

- Saham Panin Sekuritas Tbk
- Model Linier & Model Non Linier



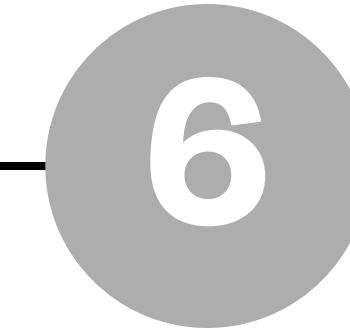
## Bab 3

- Sumber Data
- Variabel Penelitian



## Bab 4

- Model Linier (ARIMA)
- Model Non Linier (LSTM)
- Perbandingan Evaluasi

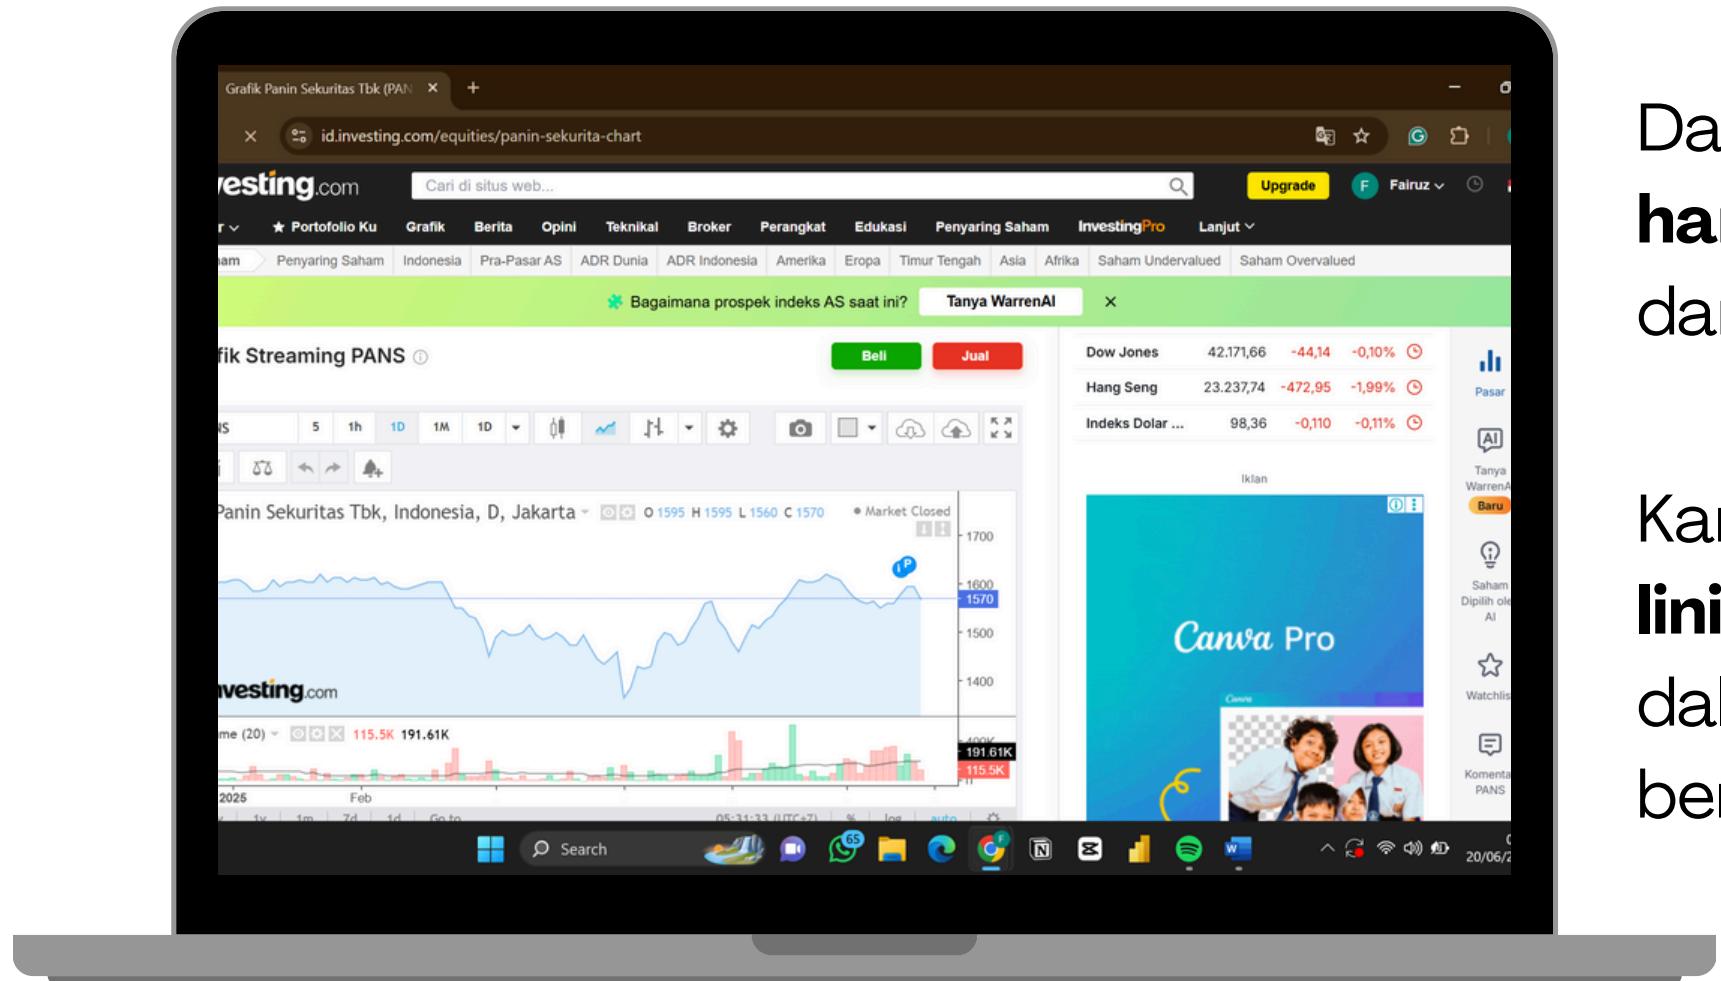


## Bab 5

- Kesimpulan
- Saran

# Bab 1: Latar Belakang

X



Data yang kami gunakan adalah **saham harian Panin Sekuritas Tbk** yang dimulai dari rentang **tahun 2020 hingga 2025**

Kami menggunakan **2 metode**, yaitu **metode linier (ARIMA)** dan **metode non linier (LSTM)** dalam membandingkan lebih baik mana berdasarkan metrik **evaluasi model MAPE**

# Bab 1: Rumusan Masalah & Tujuan

Mengacu pada latar belakang yang telah dijelaskan sebelumnya, berikut adalah **rumusan masalah** dalam penelitian ini.

Bagaimana kinerja model linier ARIMA dalam meramalkan harga saham Panin Sekuritas Tbk berdasarkan data historis?

Bagaimana kinerja model non-linier LSTM dalam meramalkan harga saham Panin Sekuritas Tbk?

Model manakah yang memiliki tingkat akurasi lebih tinggi dalam peramalan harga saham Panin Sekuritas Tbk, antara ARIMA dan LSTM?

Sebagai jawaban atas rumusan permasalahan yang dirumuskan sebelumnya, berikut ini disampaikan **tujuan** dari penelitian ini.

Menganalisis kinerja model ARIMA dalam peramalan harga saham Panin Sekuritas Tbk.

Menganalisis kinerja model LSTM dalam peramalan harga saham Panin Sekuritas Tbk.

Membandingkan tingkat akurasi prediksi antara model ARIMA dan model LSTM menggunakan metrik evaluasi.

# Bab 1: Manfaat

Analisis ini memiliki beberapa manfaat, bagi Perusahaan Panin Sekuritas Tbk, penulis, serta pembaca.

## Bagi Perusahaan

1. Memberikan gambaran tentang metode prediksi harga saham yang lebih akurat dan relevan.
2. Membantu dalam pengambilan keputusan investasi berdasarkan hasil prediksi yang lebih tepat.
3. Meningkatkan efisiensi analisis internal dengan menggunakan pendekatan berbasis data.
4. Menyediakan dasar bagi pengembangan sistem prediksi otomatis dalam platform investasi perusahaan.
5. Meningkatkan daya saing melalui pemanfaatan teknologi canggih seperti machine learning.

## Bagi Penulis

1. Meningkatkan pemahaman terhadap penerapan model statistik dan deep learning dalam peramalan deret waktu.
2. Mengembangkan kemampuan analisis data, pemrograman, dan evaluasi model prediktif.
3. Memberikan pengalaman praktis dalam mengerjakan proyek penelitian berbasis data nyata.
4. Menjadi bekal akademik dan profesional dalam bidang data science dan analisis keuangan.
5. Memperluas wawasan terhadap potensi penerapan teknologi AI dalam sektor keuangan.

## Bagi Pembaca

1. Menambah pengetahuan mengenai perbedaan pendekatan model linier dan non-linier dalam prediksi saham.
2. Memberikan referensi empiris dalam studi peramalan harga saham di pasar modal Indonesia.
3. Menjadi acuan bagi penelitian lanjutan di bidang statistik, machine learning, dan keuangan.
4. Memberikan wawasan praktis dalam memilih model prediksi yang sesuai untuk data pasar.
5. Mendorong minat untuk mengembangkan aplikasi teknologi cerdas dalam dunia keuangan.

## Bab 2: Saham Panin Sekuritas Tbk

---

x



Panin Sekuritas merupakan salah satu **Perusahaan Efek terkemuka** yang hadir untuk menjawab kebutuhan investasi para Investor, baik perorangan, perusahaan swasta, maupun lembaga pemerintahan.

Solusi cerdas yang kami berikan didasari oleh pengetahuan yang mendalam atas kebutuhan investasi para Nasabah kami.

# Bab 2: Model Linier (ARIMA) & Model Non-Linier (LSTM)

x

Berikut merupakan perbedaan antara kedua metode linier (ARIMA) dengan model non-linier (LSTM)

## Model Linier (ARIMA)

Analisis deret waktu digunakan untuk memodelkan data berkala seperti harga saham yang fluktuatif. Model ARIMA sering digunakan karena mampu menangkap pola stasioner secara linier, meskipun memiliki keterbatasan dalam menghadapi pola yang lebih kompleks. Perbandingan dengan model lain diperlukan untuk menentukan pendekatan prediksi yang paling akurat dan sesuai dalam konteks data keuangan.

## Model Non-Linier (LSTM)

Model LSTM (Long Short-Term Memory) sering digunakan karena kemampuannya yang unggul dalam menangkap pola non-linier dan dependensi jangka panjang dalam data. Sebagai jenis Jaringan Saraf Tiruan Berulang (RNN), LSTM sangat efektif untuk data sekuensial yang kompleks dan volatil, mengatasi keterbatasan yang dimiliki model linier tradisional. Meskipun demikian, perbandingan dengan model lain tetap diperlukan untuk menentukan pendekatan prediksi yang paling akurat dan sesuai

Terlihat bahwa jelas perbedaannya bahwa model ARIMA lebih baik digunakan pada data yang memenuhi asumsi linieritas sedangkan model LSTM tidak

# Bab 3: Sumber Data & Variabel Penelitian

x

## Sumber Data

Data yang digunakan dalam penelitian ini adalah data sekunder yang diperoleh dari situs resmi investing.com. Data saham yang dipilih adalah saham PT Panin Sekuritas Tbk (PANS) dimana mencakup historis harga penutupan, harga pembukaan, harga terendah, dan harga tertinggi harian dari tanggal 20 Januari 2020 hingga 18 Juni 2025.

## Variabel Penelitian

Variabel yang digunakan pada penelitian ini adalah harga penutupan harian (Close Price). Harga penutupan harian (Closing Price) dipilih sebagai variabel utama karena merepresentasikan konsensus akhir sentimen pasar pada hari perdagangan, berfungsi sebagai acuan penting bagi investor dan trader untuk hari berikutnya, meminimalisir volatilitas jangka pendek (intraday noise), serta merupakan data yang umum dan mudah diakses dalam studi peramalan pasar keuangan

# Bab 4: Preprocessing

	Tanggal	Terakhir	Pembukaan	Tertinggi	Terendah	Vol.	Perubahan%
0	18/06/2025	1.595	1.600	1.605	1.590	189,60K	0,00%
1	17/06/2025	1.595	1.580	1.600	1.580	276,00K	0,95%
2	16/06/2025	1.580	1.560	1.590	1.555	155,60K	1,28%
3	13/06/2025	1.560	1.565	1.570	1.550	353,10K	0,00%
4	12/06/2025	1.560	1.565	1.570	1.555	339,10K	0,65%

Tidak Ada Missing Value

- Mengubah Format Tanggal & Menjadikan Index Time Series
- Tanda “titik” Masih Terbaca Koma Dan Mengubah Ke Bentuk Numerik

Tanggal	Terakhir	Pembukaan	Tertinggi	Terendah	Vol.	Perubahan%
2025-06-12	1560	1565	1570	1555	339,10K	0,65%
2025-06-13	1560	1565	1570	1550	353,10K	0,00%
2025-06-16	1580	1560	1590	1555	155,60K	1,28%
2025-06-17	1595	1580	1600	1580	276,00K	0,95%
2025-06-18	1595	1600	1605	1590	189,60K	0,00%

Terakhir  
Pembukaan  
Tertinggi  
Terendah  
Vol.  
Perubahan%  
dtype: int64

# Bab 4: Exploratory Data

x

## STATISTIKA DESKRIPTIF

	Terakhir	Pembukaan	Tertinggi	Terendah
count	1300.000000	1300.000000	1300.000000	1300.000000
mean	1451.150000	1453.650000	1471.192308	1434.146154
std	326.155264	325.139996	323.997776	326.563395
min	640.000000	625.000000	680.000000	625.000000
25%	1265.000000	1270.000000	1285.000000	1250.000000
50%	1555.000000	1552.500000	1570.000000	1535.000000
75%	1670.000000	1670.000000	1685.000000	1655.000000
max	2090.000000	2130.000000	2190.000000	2050.000000

Harga penutupan harian saham PANS selama periode pengamatan memiliki rata-rata harga sebesar 1451.15 dengan standar deviasi 326.155. Nilai standar deviasi yang cukup besar relatif terhadap rata-rata mengindikasikan adanya volatilitas atau fluktuasi harga yang signifikan

## PLOT TIME SERIES

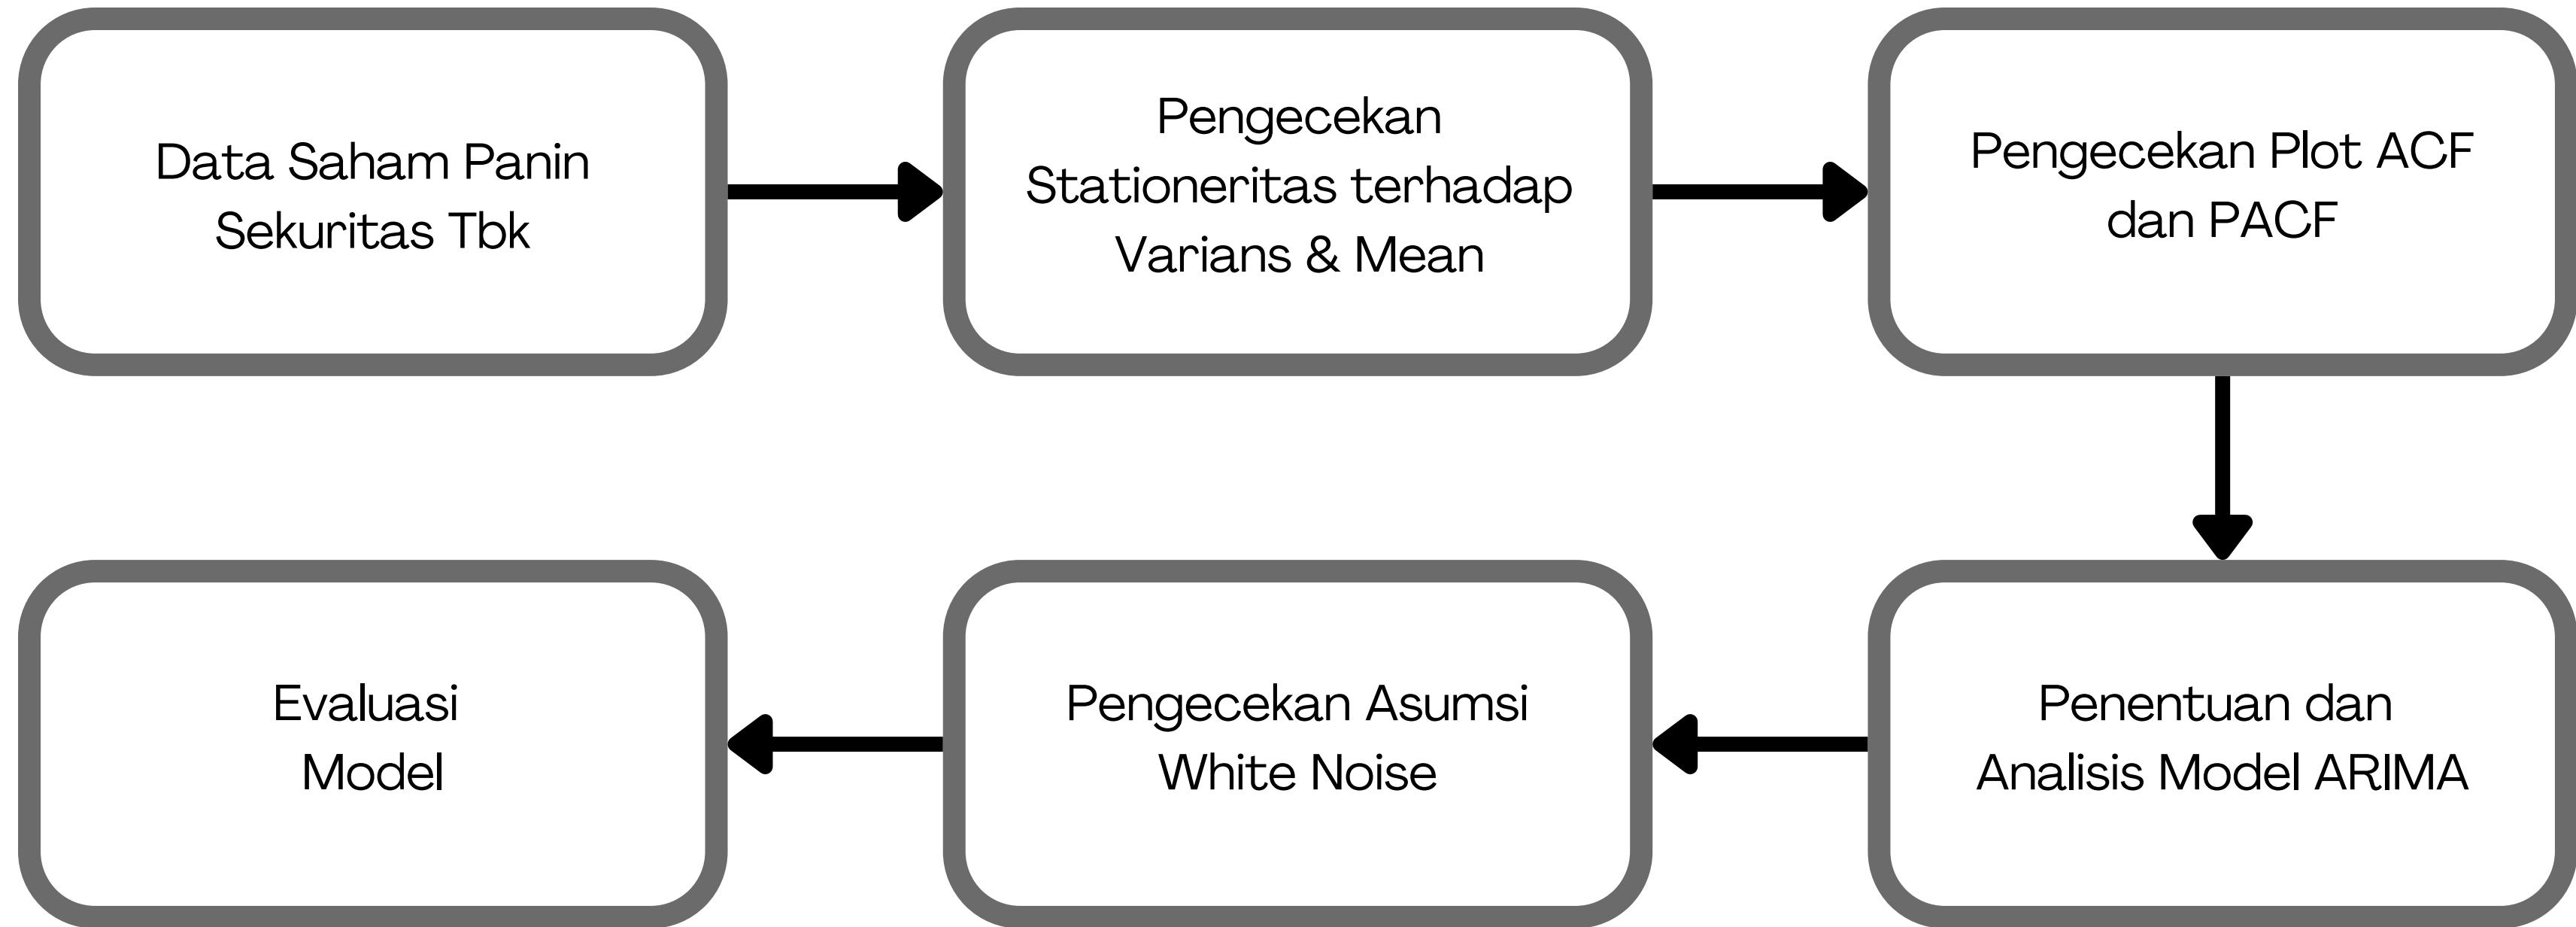


Harga penutupan harian saham PANS menunjukkan fluktuasi yang signifikan sepanjang periode pengamatan. Teridentifikasi adanya tren penurunan yang cukup jelas di awal periode, kemudian kenaikan tajam yang diikuti penurunan kembali, dan diakhiri dengan pergerakan yang cenderung stabil namun masih menunjukkan volatilitas

# Bab 4: Analisis Metode Linier (ARIMA)

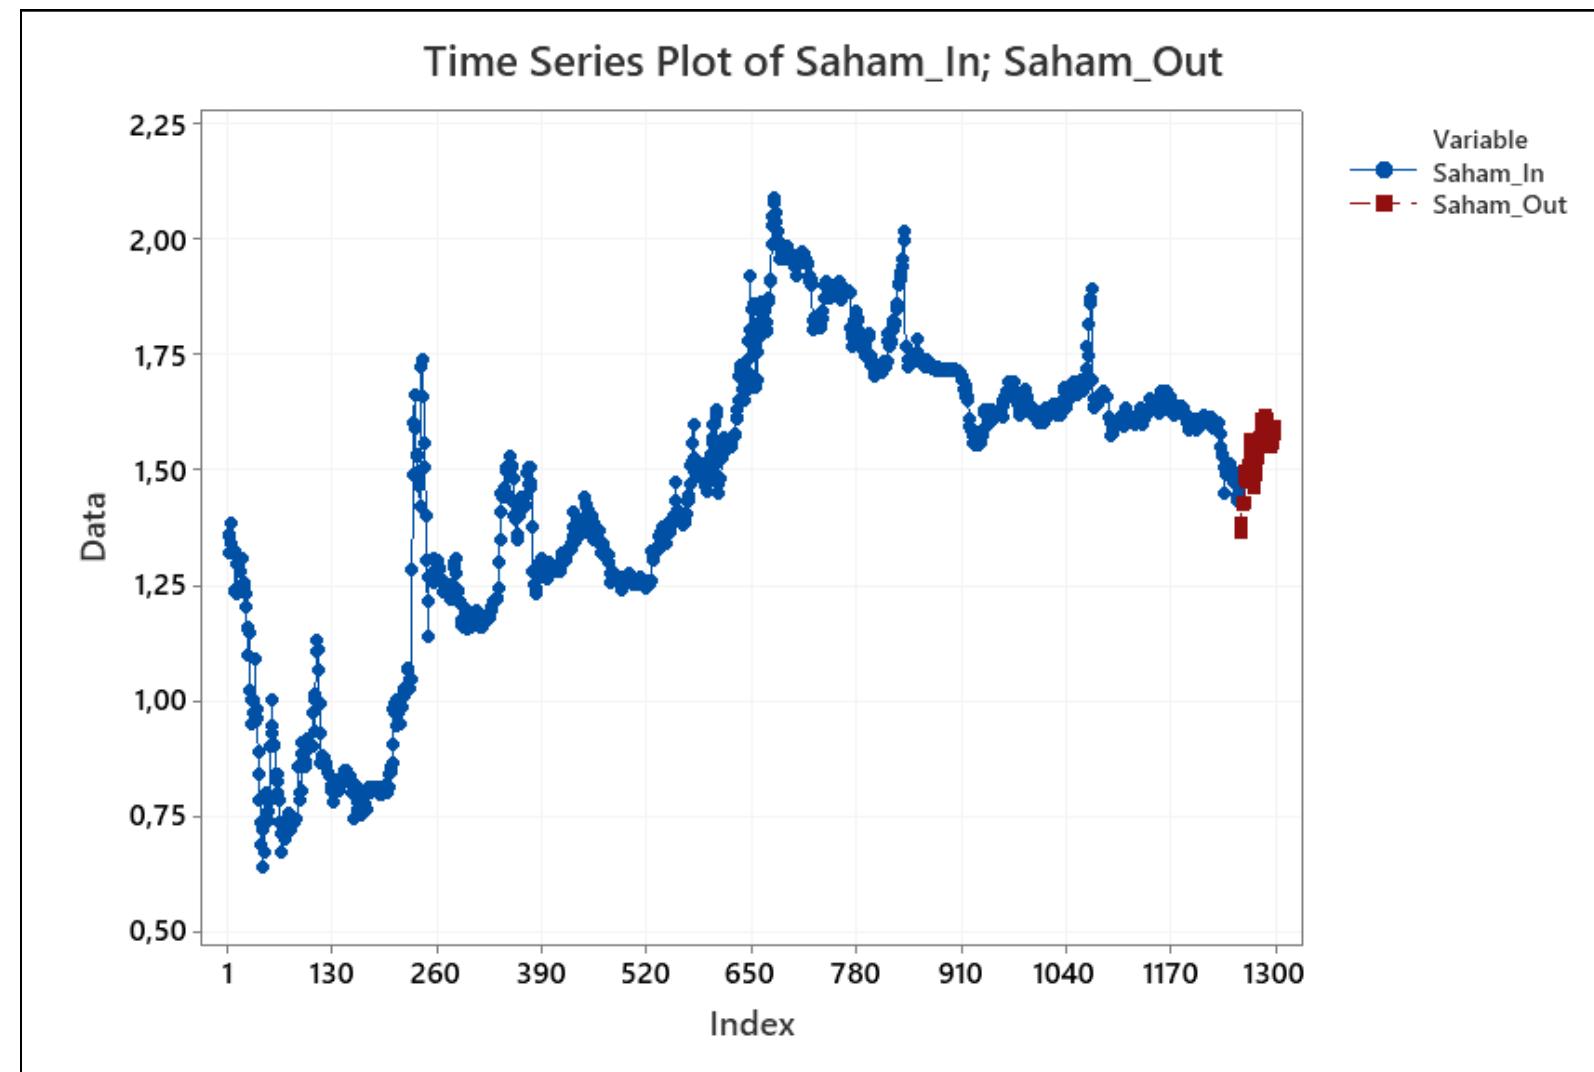
x

Berikut merupakan langkah analisis yang dilakukan menggunakan **metode linier**, yaitu **ARIMA**.



## Bab 4: Analisis Metode Linier (ARIMA)

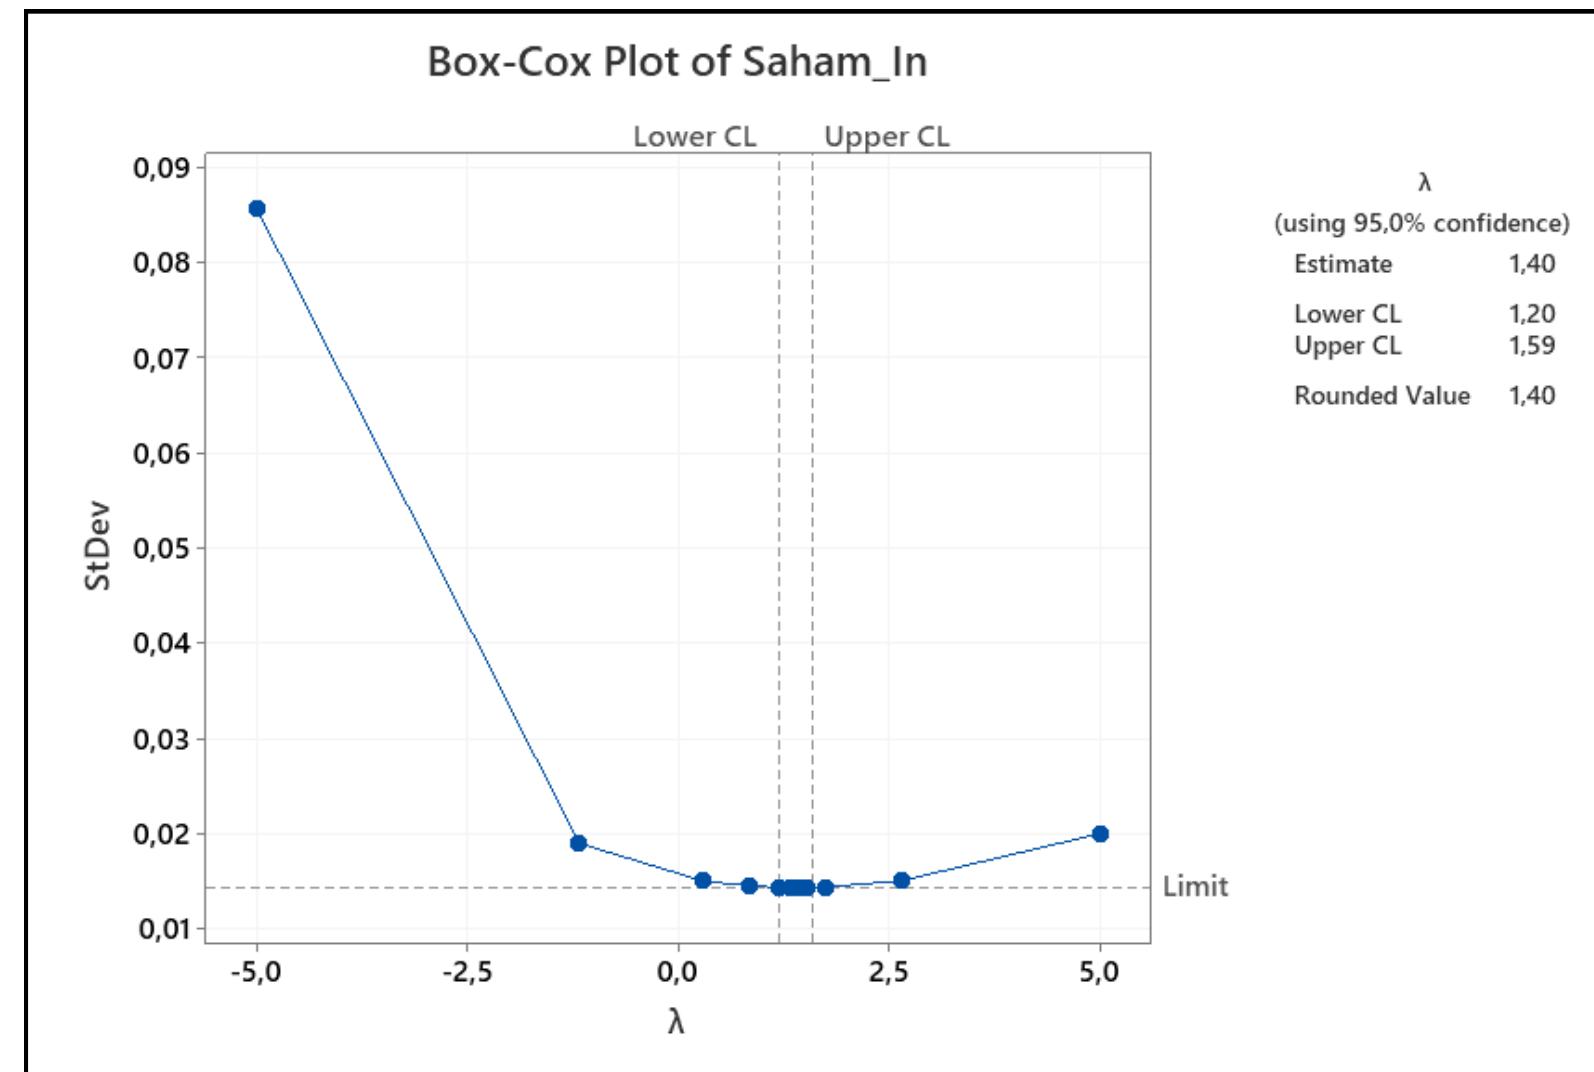
Sebelum kita melakukan analisis yang lebih dalam, dilakukan **visualisasi plot time series** data saham **yang telah displitting** sebagai berikut.



Didapatkan hasil seperti di atas dengan **pola multiplicative** yang **cenderung naik** pada awalnya dan mengalami **penurunan sedikit** di akhir.

## Bab 4: Analisis Metode Linier (ARIMA)

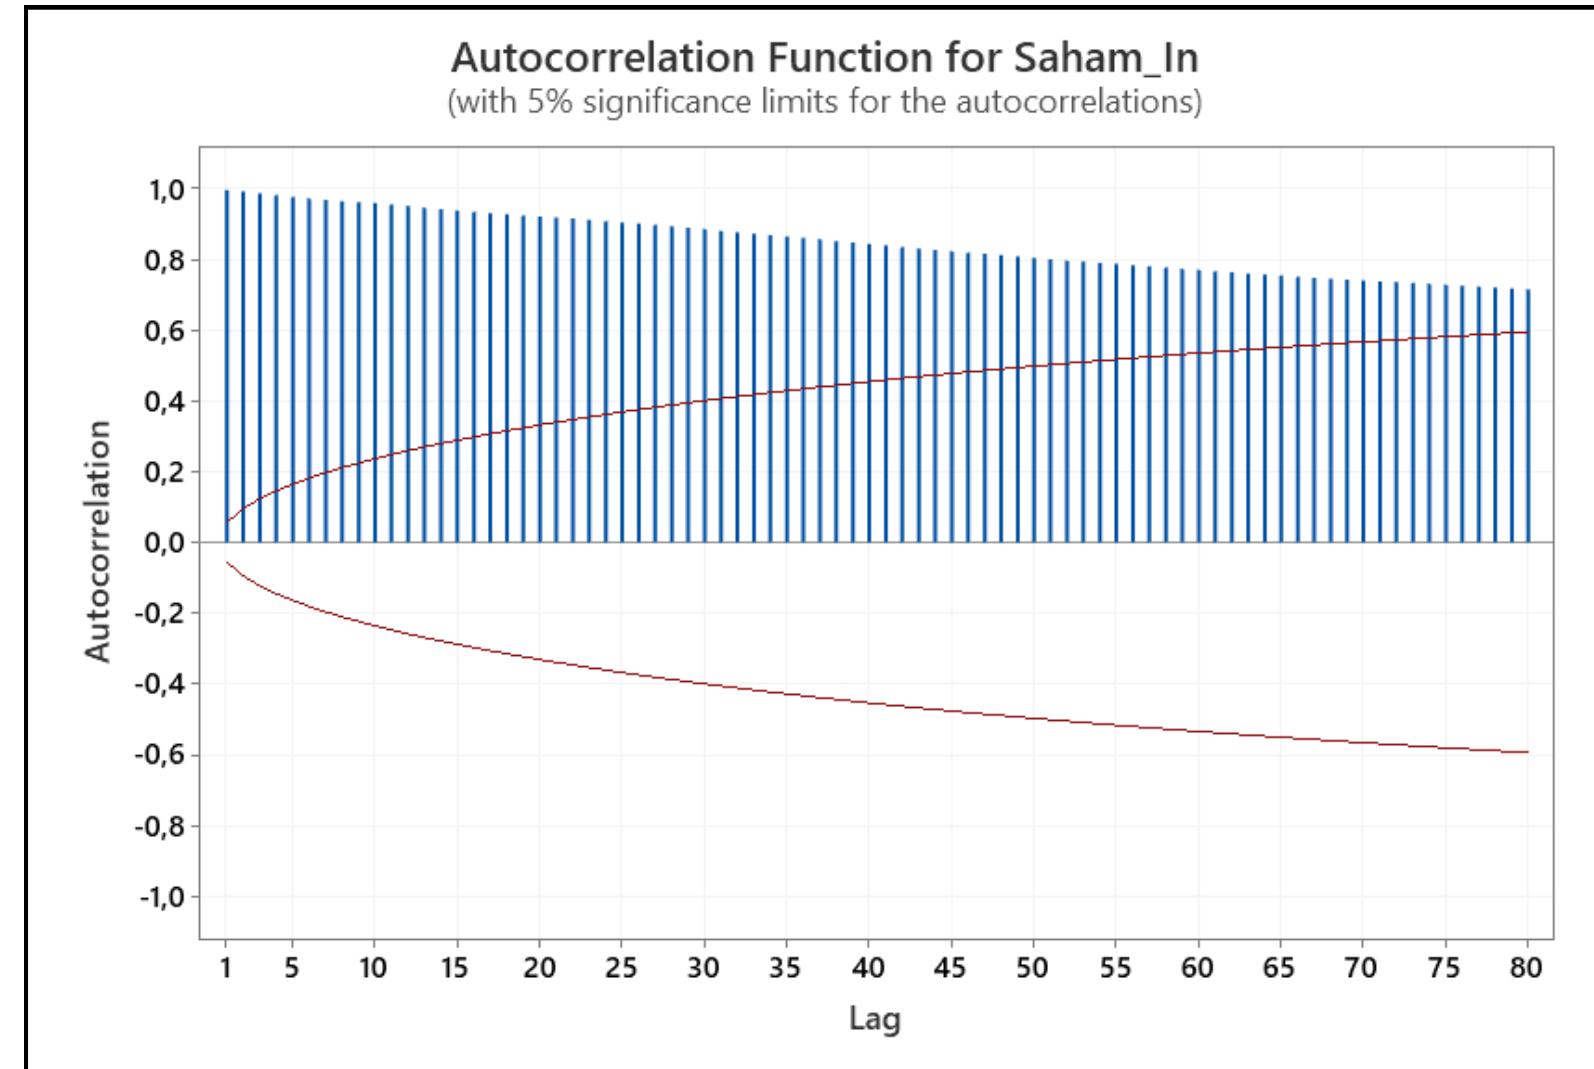
Setelah itu dilakukan pengecekan apakah data tersebut **stationer terhadap varians** atau tidak dengan **uji Box-Cox** yang didapatkan sebagai berikut.



Didapatkan hasil dari rounded valuenya sebesar 1,41 yang tidak masuk ke transformasi manapun sehingga **tidak dilakukan transformasi** untuk ingin melihat seberapa jauh dampaknya.

## Bab 4: Analisis Metode Linier (ARIMA)

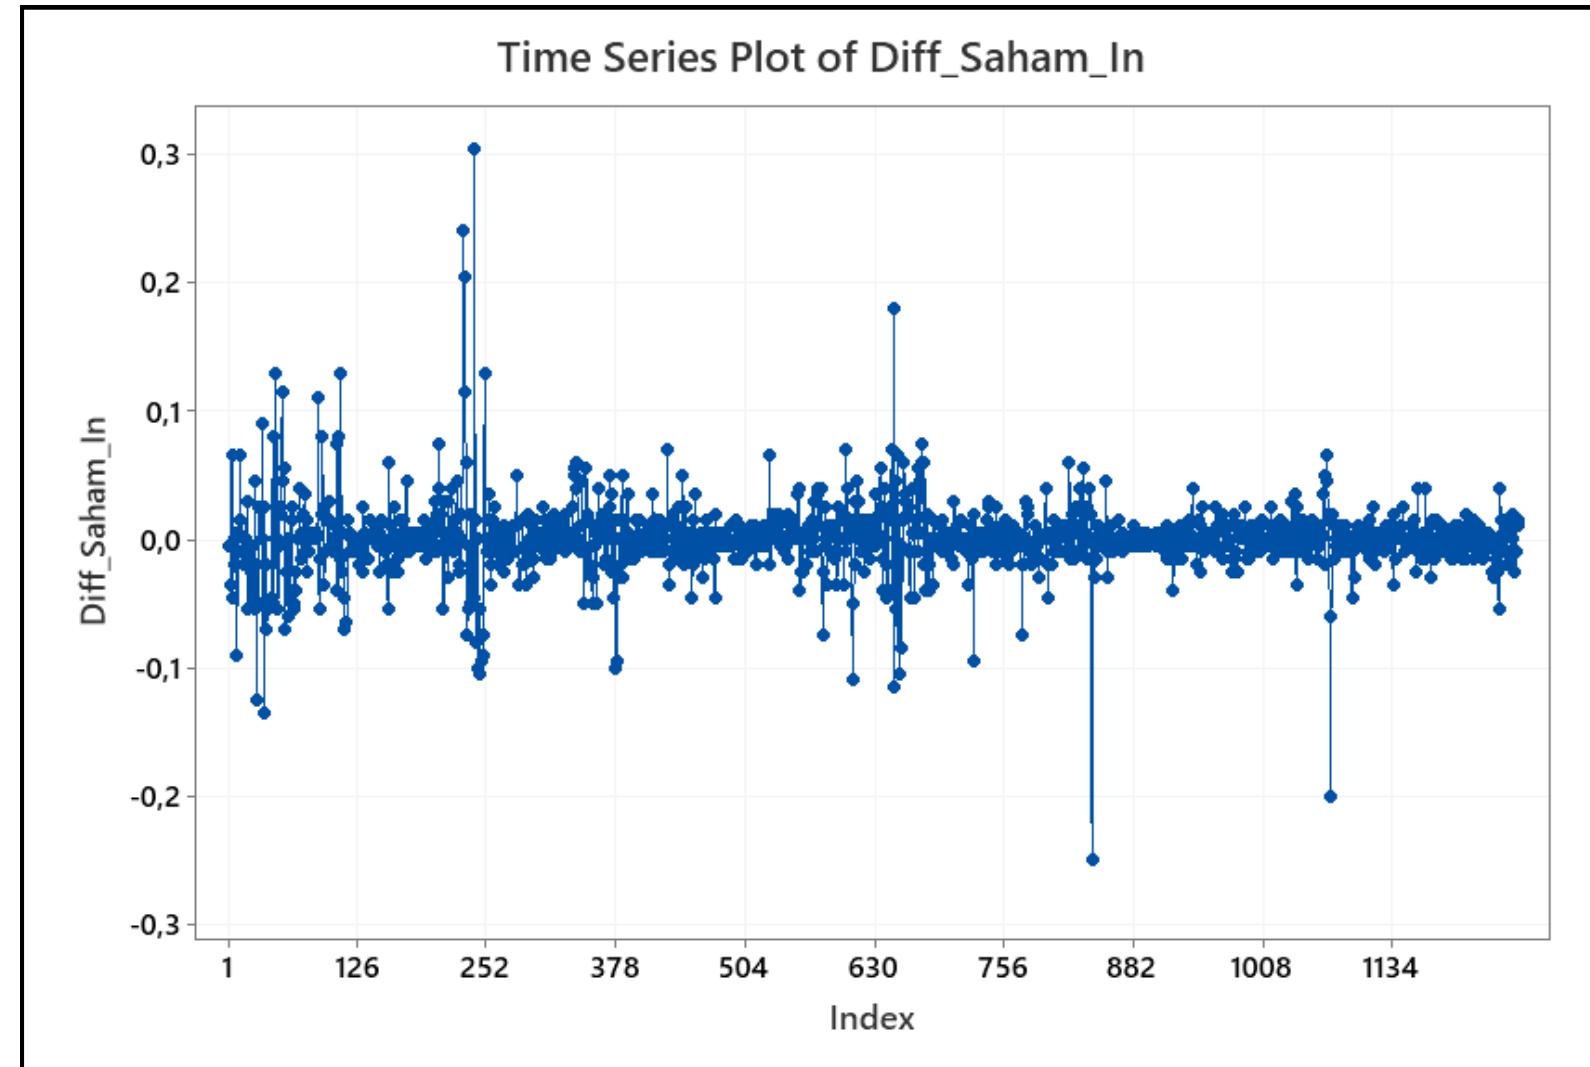
Dikarenakan sudah stationer terhadap varians, maka dilakukan pengecekan apakah data tersebut stationer terhadap mean dengan **uji ACF** pada data.



Didapatkan hasilnya adalah menurun secara melambat yang dimana menandakan data belum stationer terhadap mean sehingga perlu dilakukan differencing.

## Bab 4: Analisis Metode Linier (ARIMA)

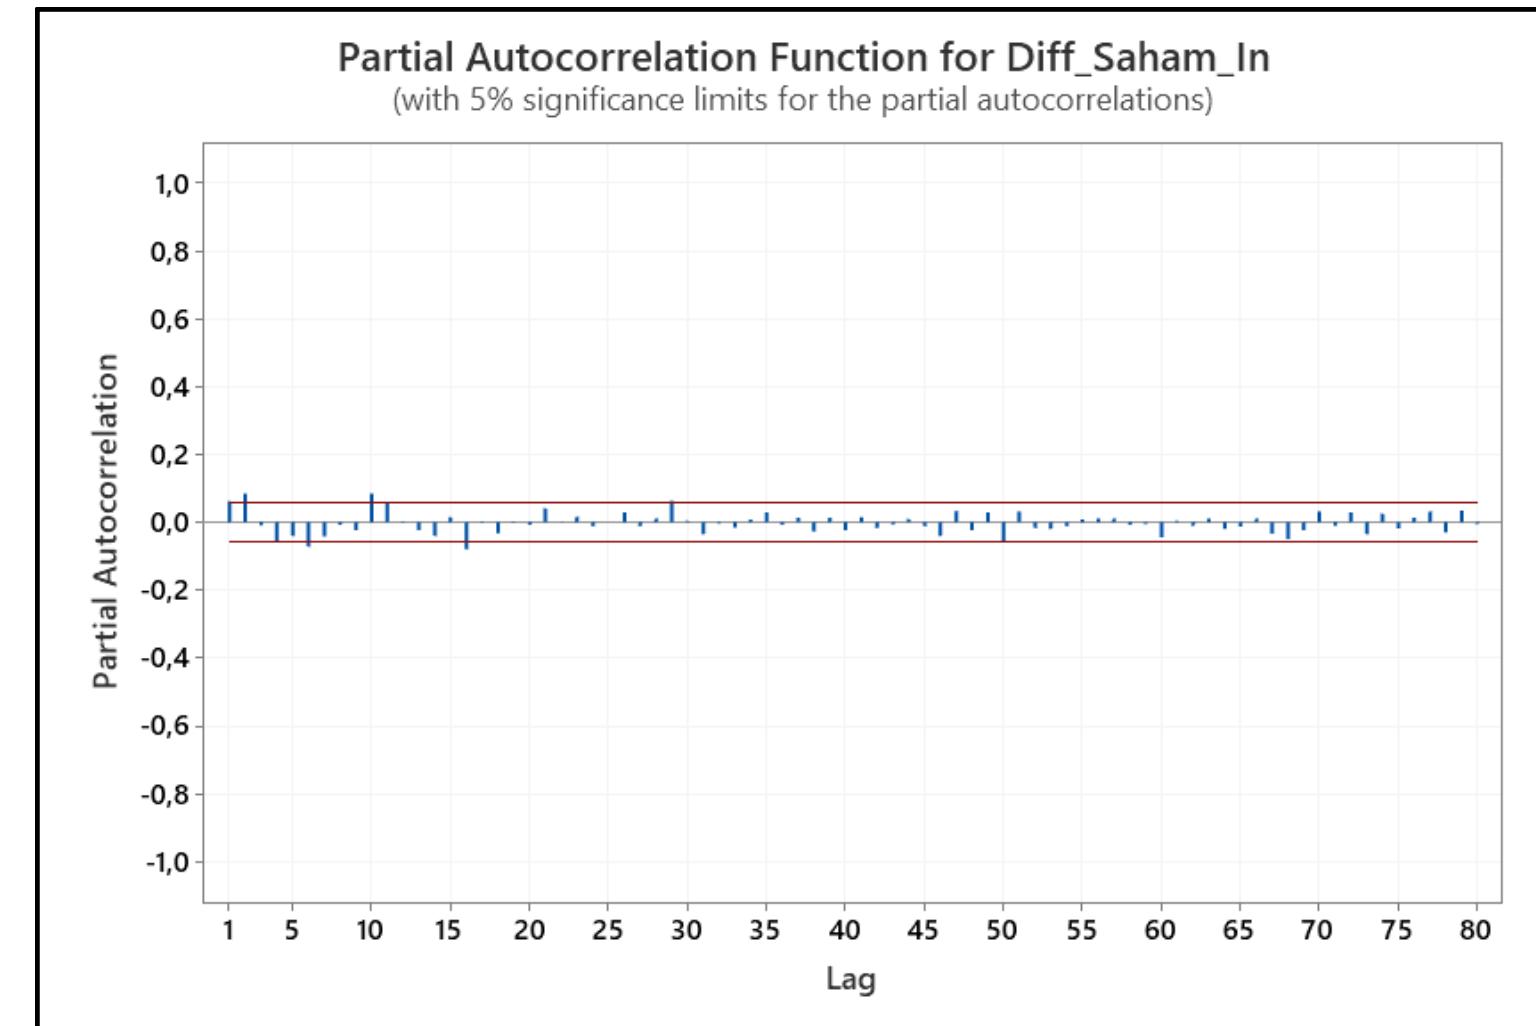
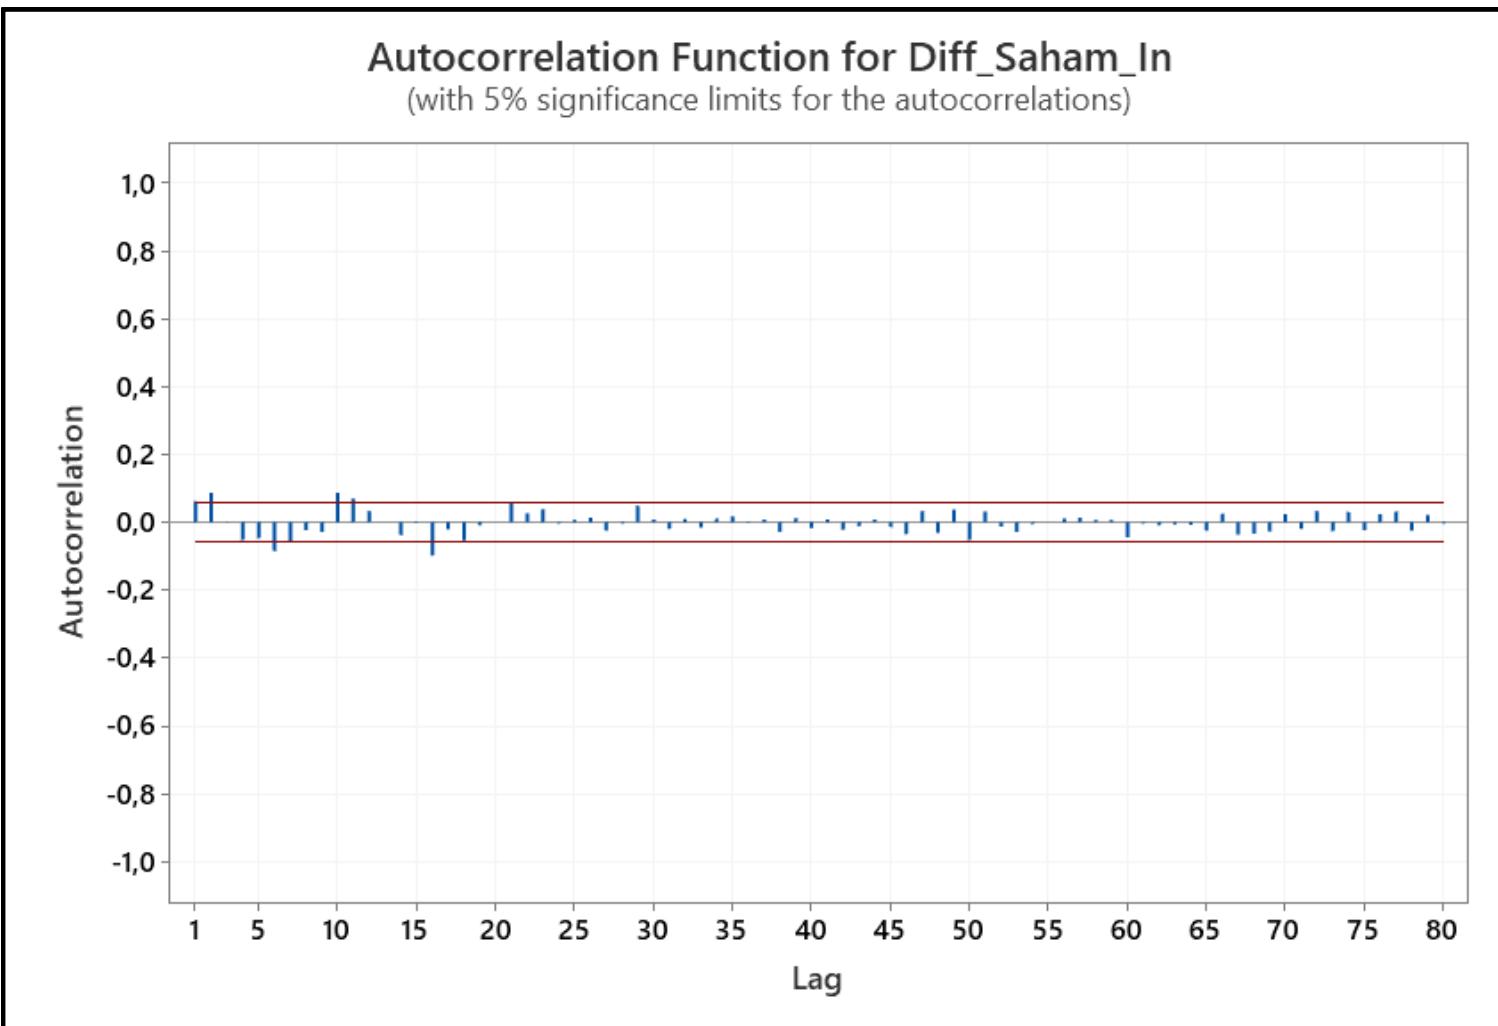
Setelah dilakukan differencing pada data, maka **divisualisasikan menggunakan plot time series** apakah sudah tersebar rata mendekati 0 atau tidak.



Hasil dari uji plot data yang sudah dilakukan differencing tersebar rata pada 0 yang menandakan bahwa data sudah stationer terhadap mean.

# Bab 4: Analisis Metode Linier (ARIMA)

Setelah data sudah stationer terhadap varians dan mean, maka dilakukan **uji ACF** dan **uji PACF** untuk menentukan model ARIMA yang tepat.



Didapatkan hasil dari ACF dan PACF adalah **dies down sinusoidal** sehingga model ARIMA yang terbentuk adalah **ARIMA (1,1,1)**

## Bab 4: Analisis Metode Linier (ARIMA)

Selanjutnya dilakukan pemodelan ARIMA(1,1,1) dan didapatkan hasil uji estimasi paramaternya sebagai berikut.

### Final Estimates of Parameters

Type	Coef	SE Coef	T-Value	P-Value
AR 1	0,440	0,292	1,50	0,133
MA 1	0,367	0,303	1,21	0,226

Dapat dilihat bahwasanya nilai p-value dari estimasi paramater ARIMA(1,1,1) semuanya di atas 0,1 yang menunjukkan bahwa **estimasi paramaternya tidak signifikan**.

## Bab 4: Analisis Metode Linier (ARIMA)

Setelah itu dilakukan **Uji Ljung-Box** untuk melihat apakah dari hasil pemodelan ARIMA(1,1,1) sudah memenuhi asumsi white noise sebagai berikut.

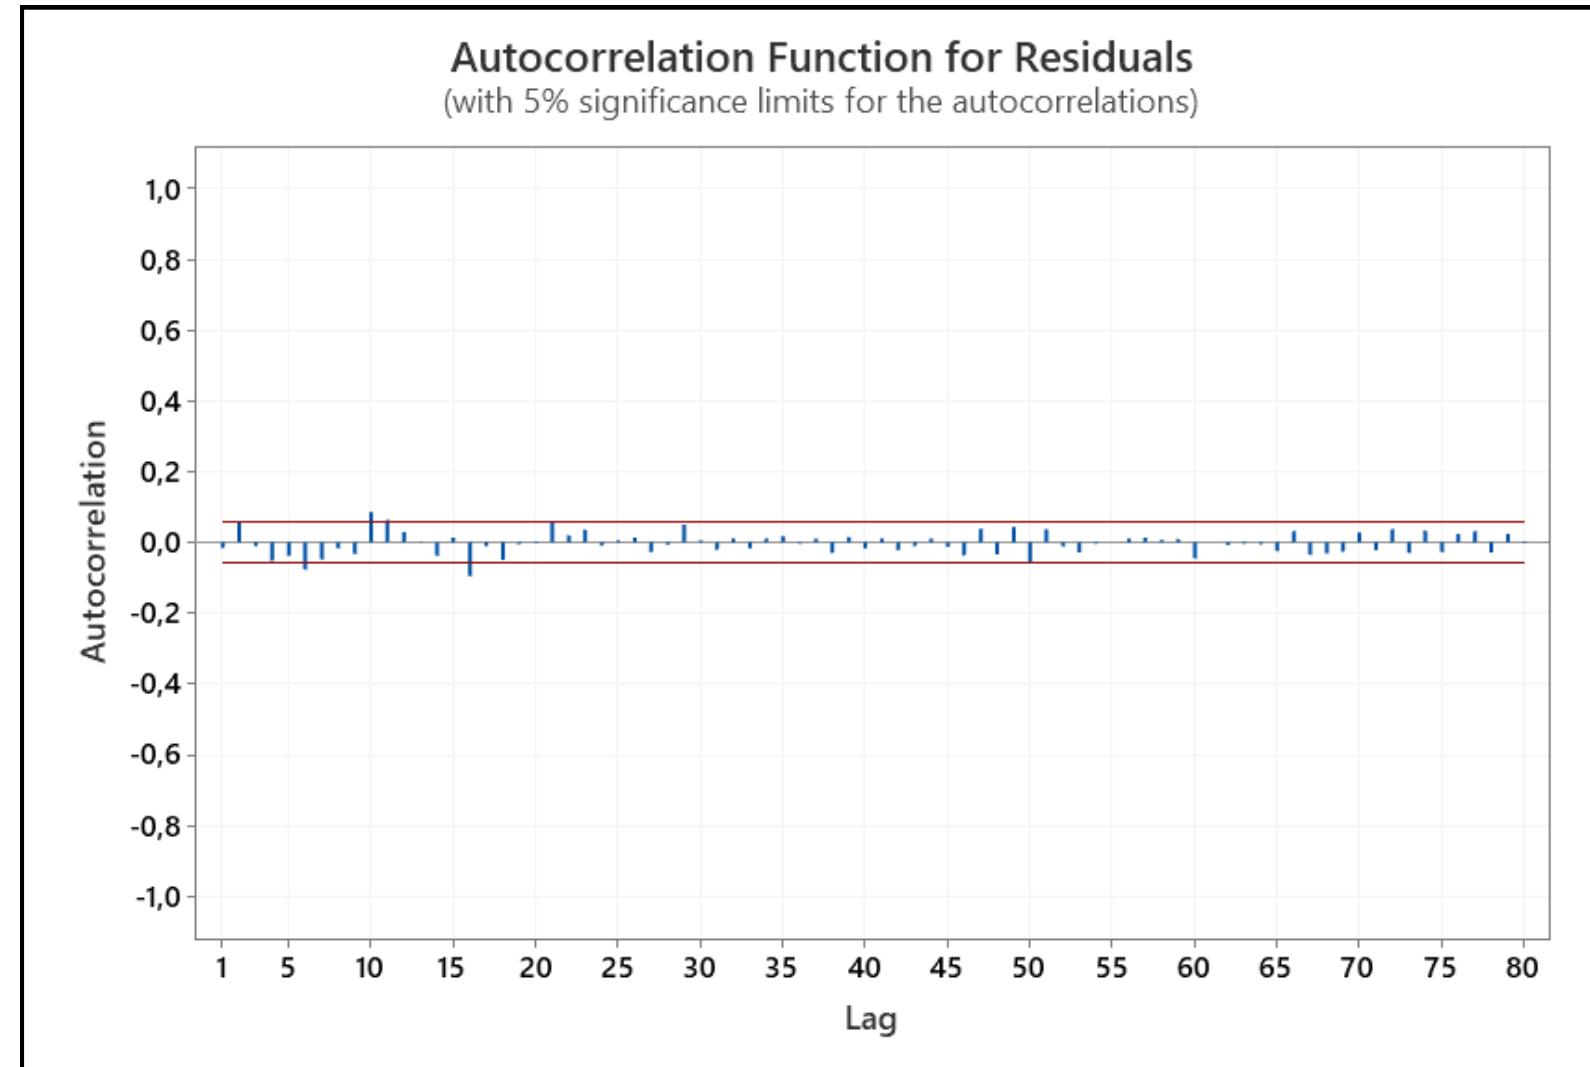
### Modified Box-Pierce (Ljung-Box) Chi-Square Statistic

Lag	12	24	36	48
Chi-Square	38,00	61,12	67,21	75,73
DF	10	22	34	46
P-Value	0,000	0,000	0,001	0,004

Dapat dilihat bahwasanya nilai p-value pada tiap lag, yaitu lag 12, 24, 36, dan 48 lebih kecil dari 0,1 yang menandakan bahwa **uji asumsi white noise tidak terpenuhi**.

## Bab 4: Analisis Metode Linier (ARIMA)

Dikarenakan tidak memenuhi signifikansi paramater dan uji asumsi *white noise*, maka dilakukan **subset ARIMA** yang dilihat dari **lag signifikan dari ACF Residual** yang dihasilkan model ARIMA(1,1,1)



Dapat dilihat bahwa lag yang signifikan adalah lag ke 2, 6, 10, dan 16. Mengacu pada aturan subset ARIMA, lag  $< 10$  masuk ke MA dan lag  $\geq 10$  masuk ke AR. Maka, terbentuk model subset **ARIMA([1 10 16], 1, [1 2 6])**.

# Bab 4: Analisis Metode Linier (ARIMA)

Setelah itu dilihat apakah parameter mode subset ARIMA tersebut sudah signifikan pada data *training* dan data *test*.

**Hasil Data Training**

Conditional Least Squares Estimation					
Parameter	Estimate	Standard	t Value	Approx	Lag
		Error		Pr >  t	
MA1,1	0.33984	0.14505	2.34	0.0193	1
MA1,2	-0.05006	0.02983	-1.68	0.0936	2
MA1,3	0.07027	0.02686	2.62	0.0090	6
AR1,1	0.38836	0.14352	2.71	0.0069	1
AR1,2	0.08525	0.02643	3.23	0.0013	10
AR1,3	-0.07786	0.02638	-2.95	0.0032	16

**Hasil Data Test**

Conditional Least Squares Estimation					
Parameter	Estimate	Standard	t Value	Approx	Lag
		Error		Pr >  t	
MA1,1	0.31553	0.21197	1.49	0.1451	1
MA1,2	0.45531	0.16712	2.72	0.0098	2
MA1,3	-0.19400	0.14575	-1.33	0.1913	6
AR1,1	0.76903	0.16313	4.71	<.0001	1
AR1,2	-0.14721	0.10244	-1.44	0.1591	10
AR1,3	0.26263	0.09990	2.63	0.0124	16

Pada **data training**, seluruh parameter signifikan dengan nilai  $p < 0.1$ . Namun, pada **data testing**, **MA1,1, MA1,3, dan AR1,3 tidak memenuhi syarat signifikansi**.

# Bab 4: Analisis Metode Linier (ARIMA)

Setelah itu dilakukan **pengecekan asumsi white noise** pada data *training* dan data *test* apakah telah memenuhi atau tidak.

## Hasil Data Training

Autocorrelation Check of Residuals									
To Lag	Chi-Square	DF	Pr > ChiSq	Autocorrelations					
6	.	0	.	0.000	0.013	-0.020	-0.042	-0.023	0.010
12	7.12	6	0.3102	-0.022	-0.017	-0.036	-0.009	0.022	0.005
18	11.36	12	0.4983	-0.012	-0.034	0.014	-0.010	0.028	-0.031
24	16.07	18	0.5876	-0.004	-0.010	0.046	0.010	0.034	-0.016
30	21.71	24	0.5967	-0.004	0.023	-0.018	0.009	0.059	0.005
36	23.99	30	0.7725	-0.026	-0.002	-0.024	0.000	0.023	-0.004
42	26.06	36	0.8889	0.008	-0.025	0.009	-0.014	0.014	-0.021
48	30.91	42	0.8967	-0.007	0.003	-0.012	-0.040	0.032	-0.030

## Hasil Data Test

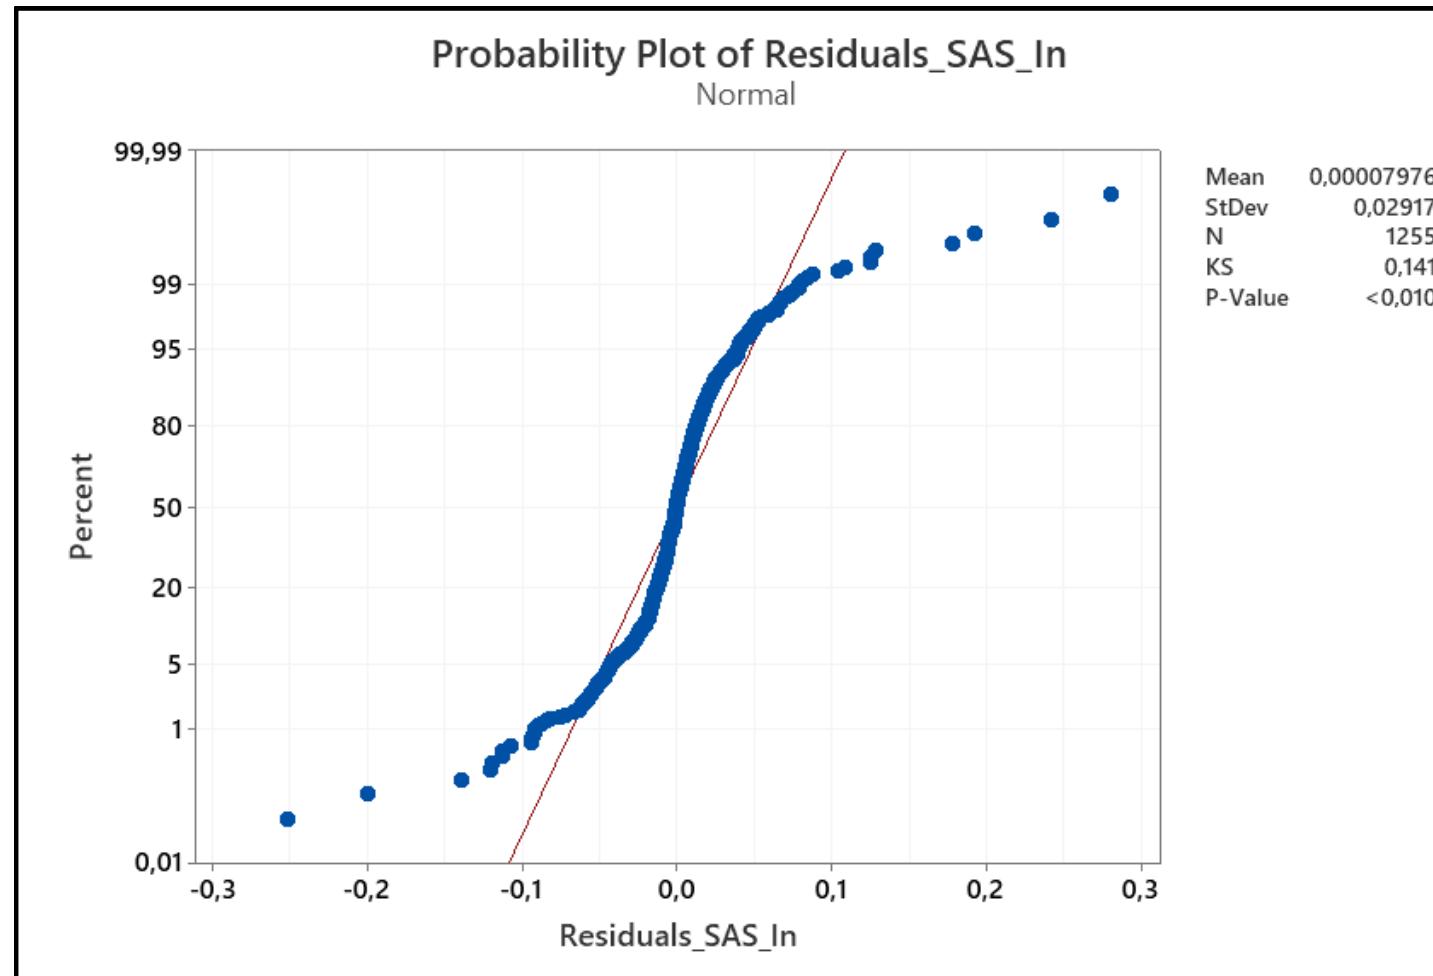
Autocorrelation Check of Residuals									
To Lag	Chi-Square	DF	Pr > ChiSq	Autocorrelations					
6	.	0	.	-0.036	-0.016	0.075	-0.066	0.051	-0.044
12	4.85	6	0.5638	0.088	0.037	-0.094	-0.003	0.109	-0.193
18	9.11	12	0.6933	0.176	0.014	-0.172	0.003	-0.031	0.044
24	11.12	18	0.8893	0.020	0.067	0.076	-0.060	-0.045	0.074
30	12.88	24	0.9680	-0.106	-0.048	-0.004	-0.032	0.001	0.032
36	18.19	30	0.9553	-0.033	0.045	-0.137	0.011	0.055	-0.038
42	25.39	36	0.9064	0.029	-0.100	0.026	0.019	-0.045	-0.017

Dapat dilihat pada kolom Pr>ChiSq pada data training dan data testing bahwa **memenuhi asumsi white noise** dikarenakan nilainya di atas taraf signifikansi, yaitu 0,1.

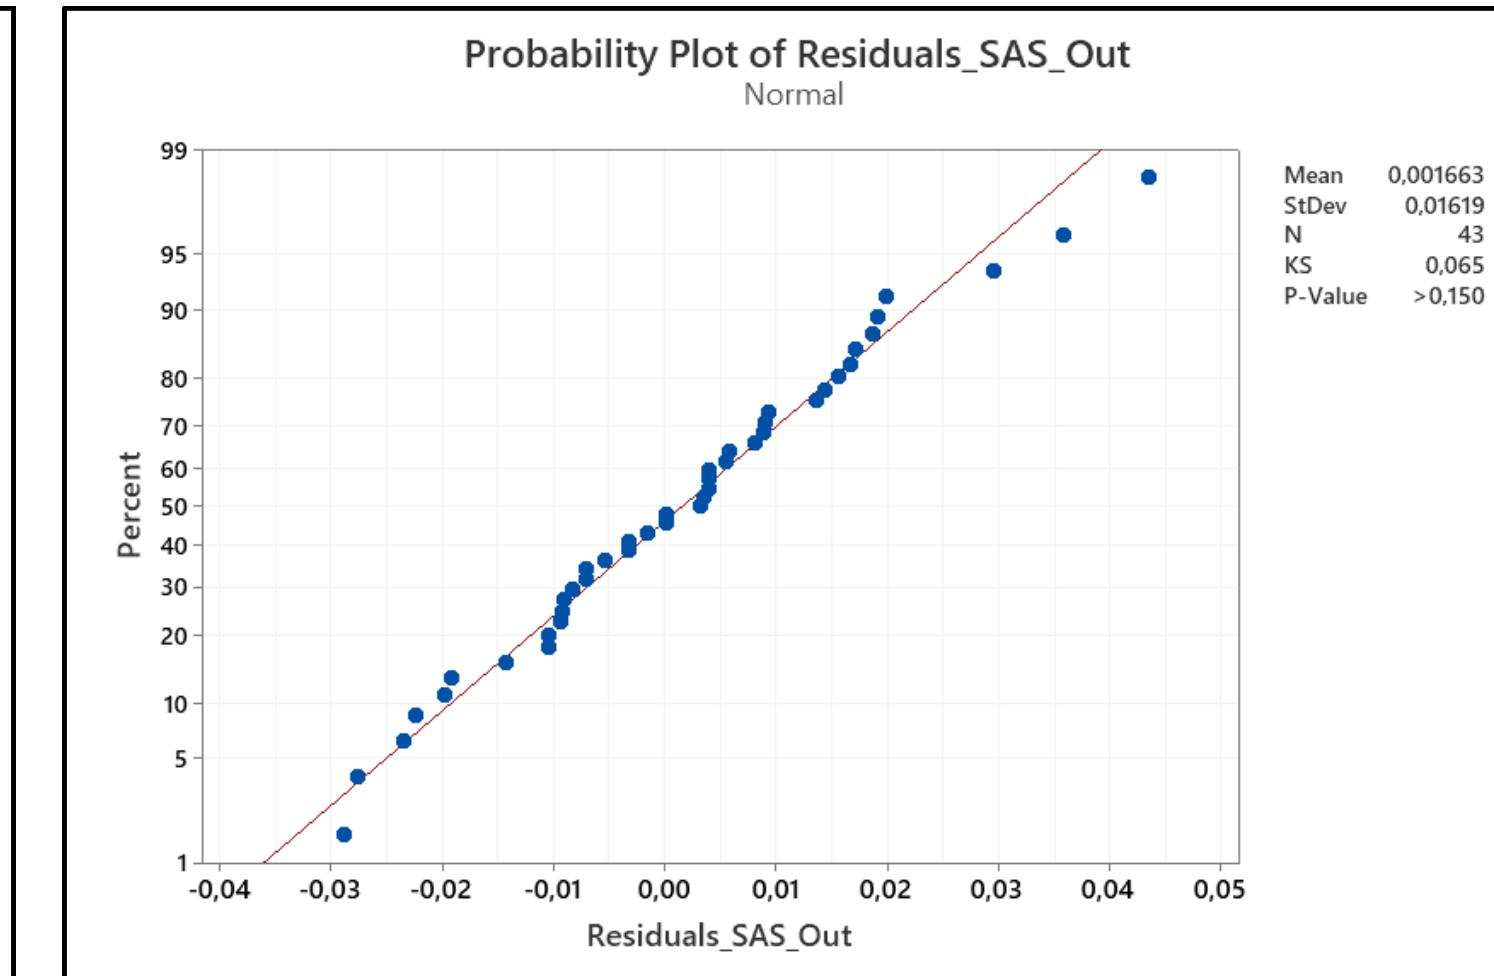
# Bab 4: Analisis Metode Linier (ARIMA)

Lalu langkah asumsi terakhir, dilakukan pengecekan apakah residual yang dihasilkan pada model subset ARIMA tersebut memenuhi normalitas atau tidak

**Hasil Data Training**



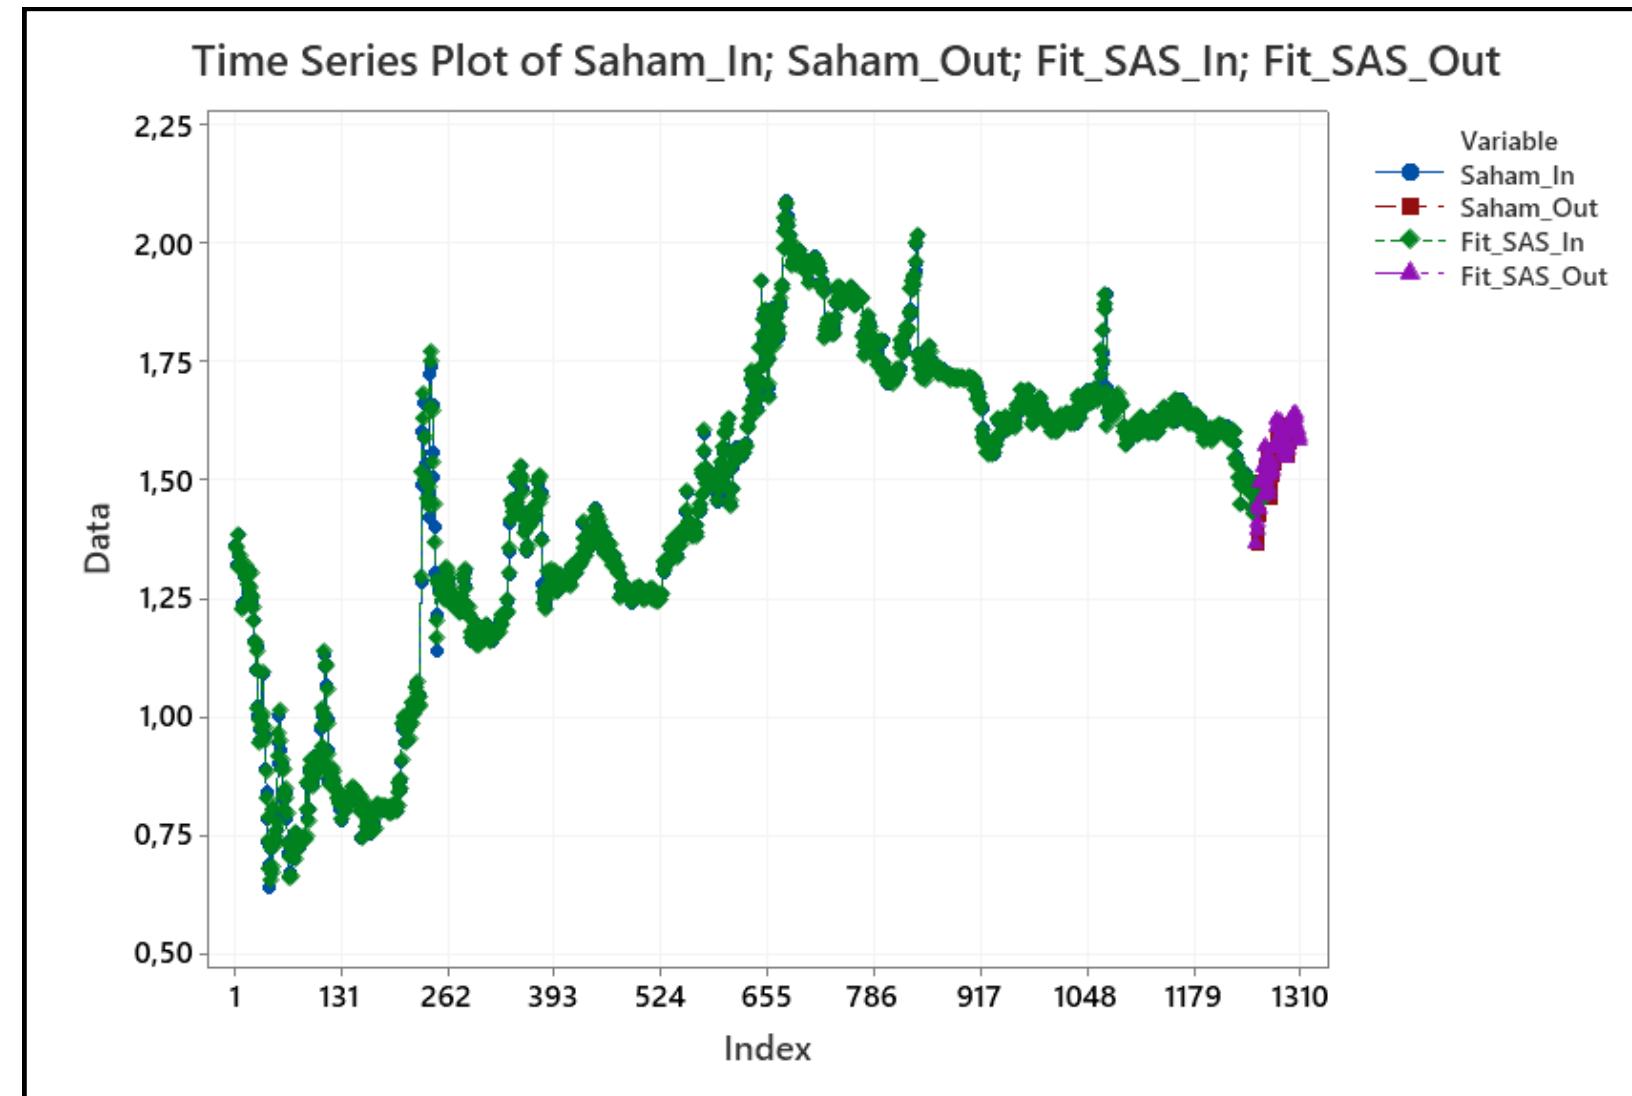
**Hasil Data Test**



Pada **data training**, residual **tidak memenuhi asumsi normalitas** karena p-value < 0,1, sedangkan pada **data testing** **asumsi normalitas terpenuhi** karena p-value > 0,1.

## Bab 4: Analisis Metode Linier (ARIMA)

Dilakukan **visualisasi plot time series** yang membandingkan antara data aktual, nilai fitted, dan hasil forecasting untuk melihat sejauh mana model mampu merepresentasikan pola data sebenarnya

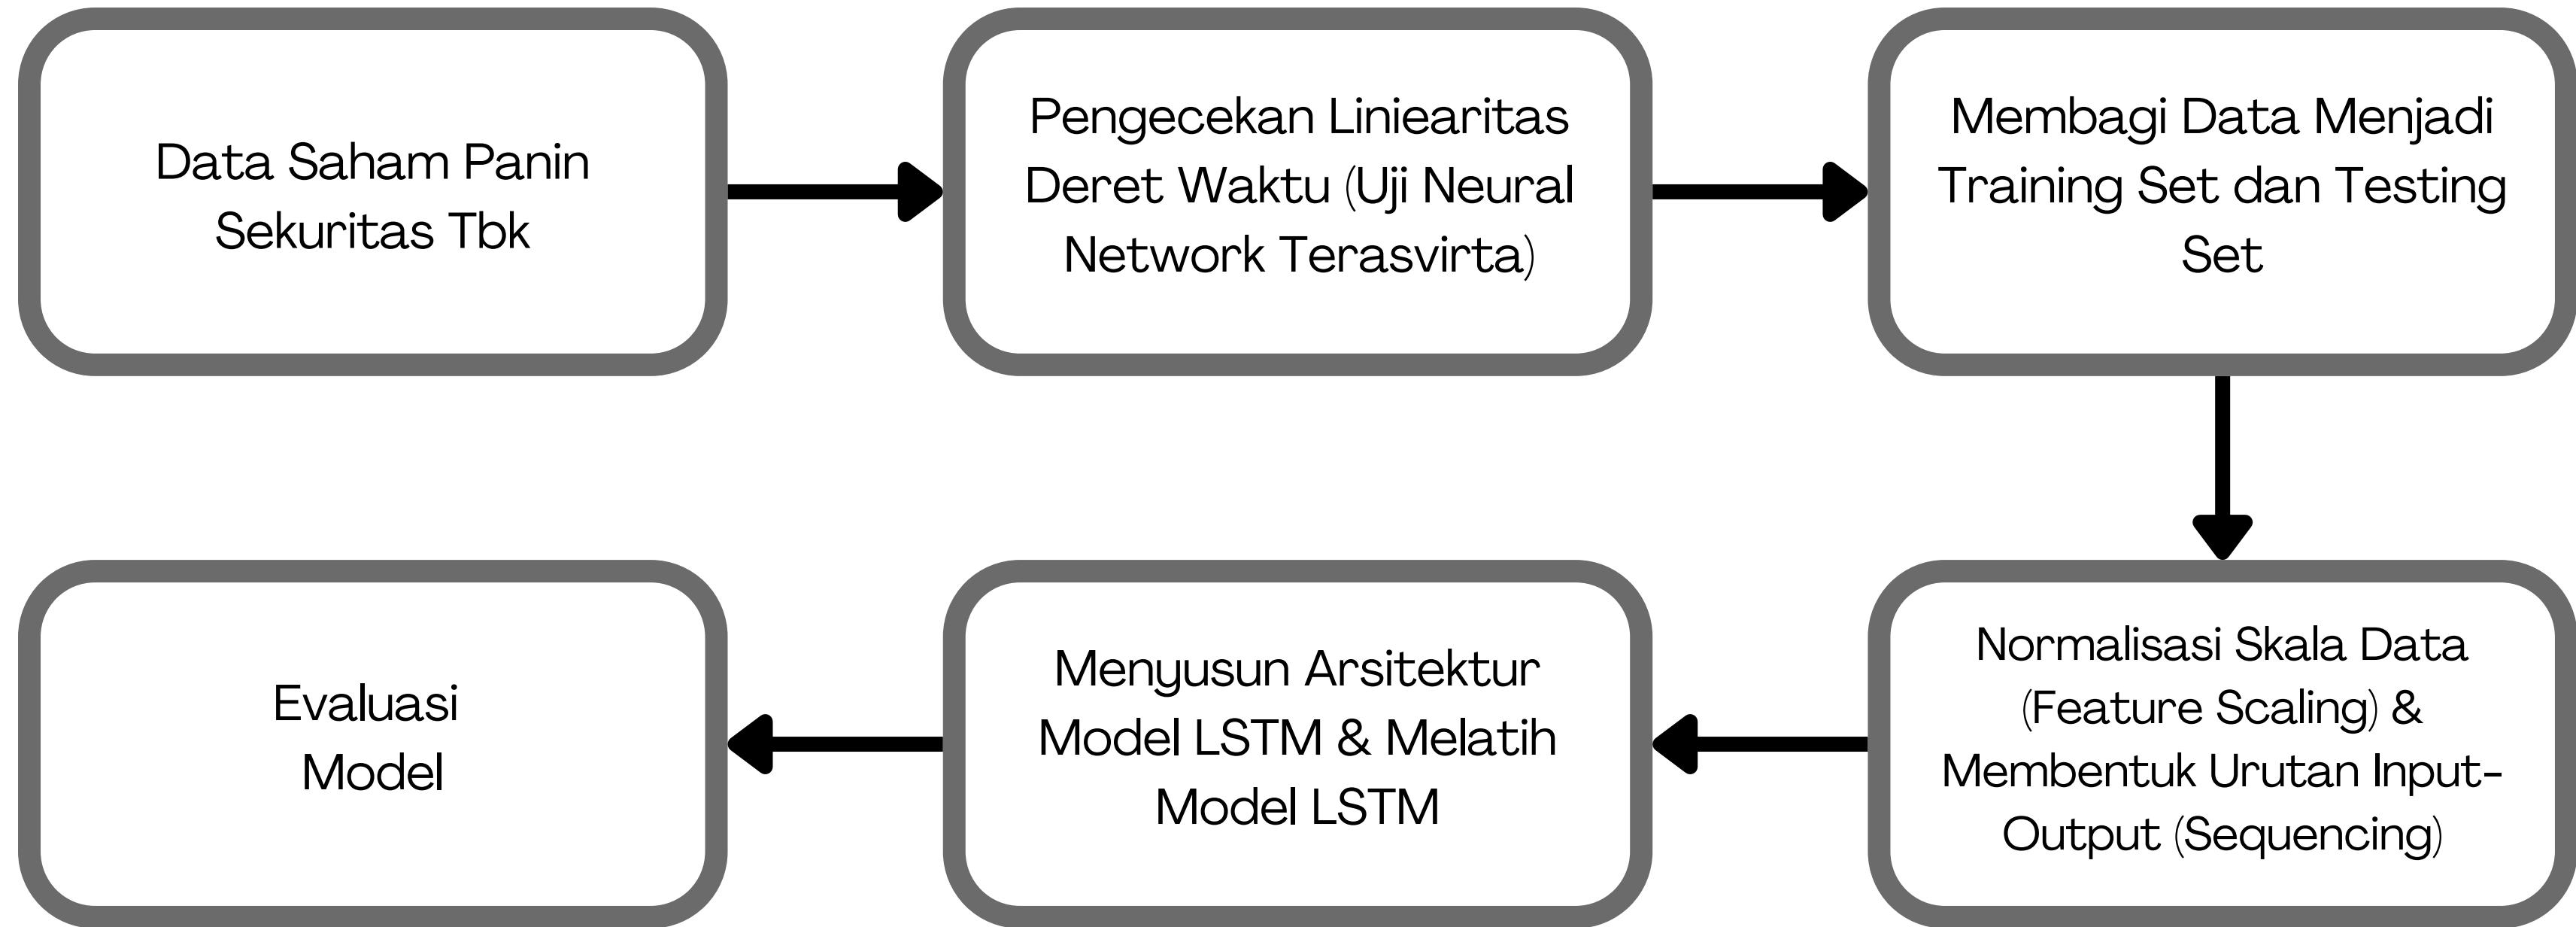


Dengan hasil fits dan forecasting seperti pada gambar, didapatkan nilai **MAPE-nya 0, 236 pada data training** dan **0,649 pada data test**.

# Bab 4: Analisis Metode Nonlinier (LSTM)

x

Berikut merupakan langkah analisis yang dilakukan menggunakan **metode nonlinier**, yaitu LSTM.



# Bab 4: Analisis Metode Nonlinier (LSTM)

x

Sebelum memulai analisis, maka dilakukan uji untuk menentukan apakah data time series yang digunakan berpola linier atau nonlinier menggunakan Uji Neural Network Terasvirta :

H<sub>0</sub> : Data deret waktu bersifat linier

H<sub>1</sub> : Data deret waktu bersifat nonlinier

```
Teraesvirta Neural Network Test

data: tplot
X-squared = 4.6074, df = 2, p-value = 0.09989
```

Hasil Uji Terasvirta menunjukkan nilai p-value sebesar 0.09989 (9,99%). Mengingat nilai p-value ini jauh lebih kecil dari tingkat signifikansi  $\alpha=10\%$ , maka kita menolak hipotesis nol ( $H_0$ ) sehingga data dapat dikatakan berpola nonlinier dan cocok untuk dianalisis menggunakan LSTM.

## Bab 4: Analisis Metode Nonlinier (LSTM)

Selanjutnya dilakukan splitting data menjadi 2 bagian yaitu set data training dan set data testing. Dalam analisis ini digunakan rasio perbandingan yaitu 90:10 dimana 90% untuk data training dan 10 % untuk data testing. Dimensi data training dan testing adalah sebagai berikut.

```
Training set - X shape: (1116, 60, 1), y shape: (1116, 1)
Testing set - X shape: (124, 60, 1), y shape: (124, 1)
```

Setelah splitting data, dilakukan normalisasi skala data untuk mengubah data mentah menjadi format yang bisa "dipahami" dan dipelajari secara efektif oleh jaringan LSTM menggunakan MinMaxScaler(). Setelah itu dilakukan sequencing data untuk menentukan urutan (sequence) data di masa lalu untuk memprediksi titik data di masa depan. Karena data yang digunakan adalah data harian maka digunakan tuning sequencing menggunakan sequencing [7,30,60].

# Bab 4: Analisis Metode Nonlinier (LSTM)

Selanjutnya adalah membentuk arsitektur yang paling optimal untuk model LSTM dengan tuning parameter model LSTM dan model LSTM yang optimal didapatkan dari :

```
# Membangun model LSTM
model_lstm = Sequential([
    LSTM(100, return_sequences=True, input_shape=(seq_length, 1)),
    Dropout(0.2),
    LSTM(100, return_sequences=False),
    Dropout(0.2),
    Dense(32),
    Dense(1)
])

model_lstm.compile(optimizer=Adam(Learning_rate=0.001), loss='mse', metrics=['mae'])
model_lstm.summary()

# Train model
history = model_lstm.fit(
    X_train, y_train,
    epochs=100,
    batch_size=32,
    validation_split=0.2,
    verbose=1
)
```

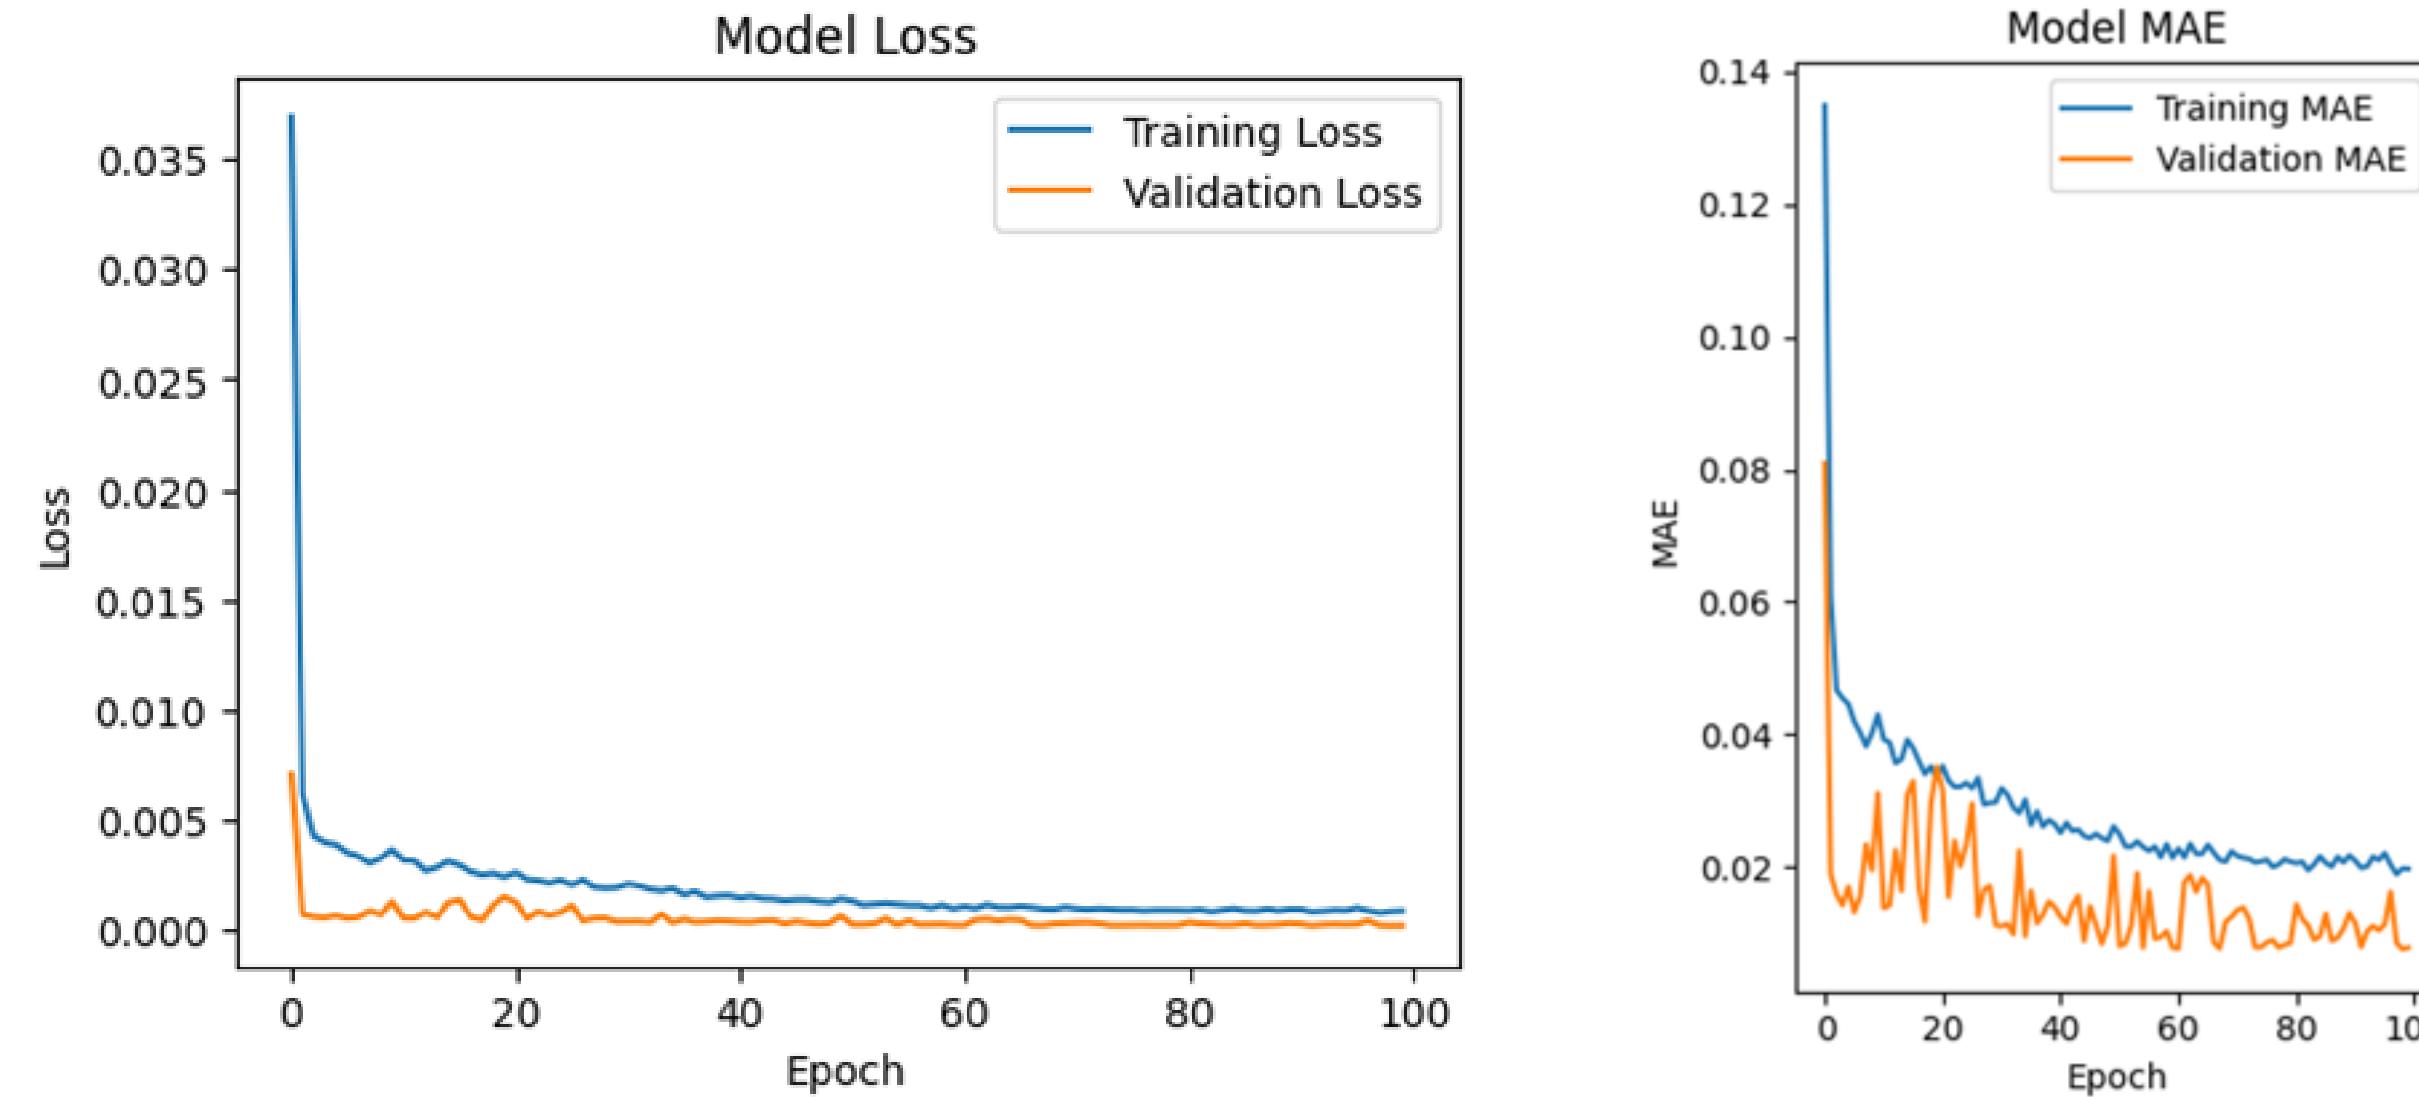
Rincian :

- 2 lapisan LSTM bertingkat
- Dropout 0,2 untuk mengurangi overfit
- Hidden layer = 1, banyak neuron = 32
- Learning rate = 0,001
- Epoch = 100
- batch\_size = 32
- validation\_split = 0,2

# Bab 4: Analisis Metode Nonlinier (LSTM)

x

Hasil dari history saat dilakukan pengujian pada data training didapatkan plot Loss dan MAE sebagai berikut

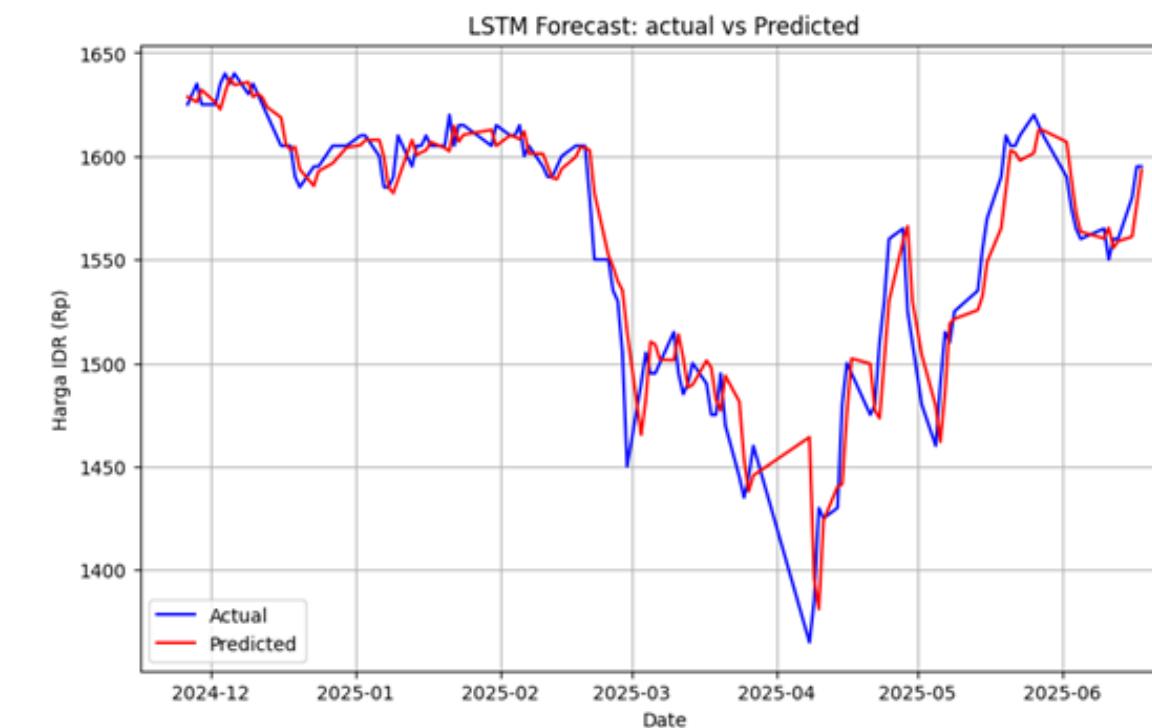


# Bab 4: Analisis Metode Nonlinier (LSTM)

Setelah dilakukan pengujian ke data testing didapatkan metrik evaluasi menggunakan Root Mean Square Error (RMSE), Mean Absolute Error (MAE), dan Mean Absolute Percentage Error dengan rincian sebagai berikut.

35/35	2s 45ms/step
Training Metrics:	
RMSE: 30.878	
MAE: 19.103	
MAPE: 1.472%	
4/4	0s 35ms/step
Test Metrics:	
RMSE: 18.775	
MAE: 12.917	
MAPE: 0.851%	

Nilai Error yang lebih kecil pada data training menunjukkan bahwa data mampu belajar dari data training dan mampu generalisasi dengan sangat baik. Nilai MAPE di bawah 2% sangat kecil menandakan prediksi model sangat akurat, baik di training maupun testing.

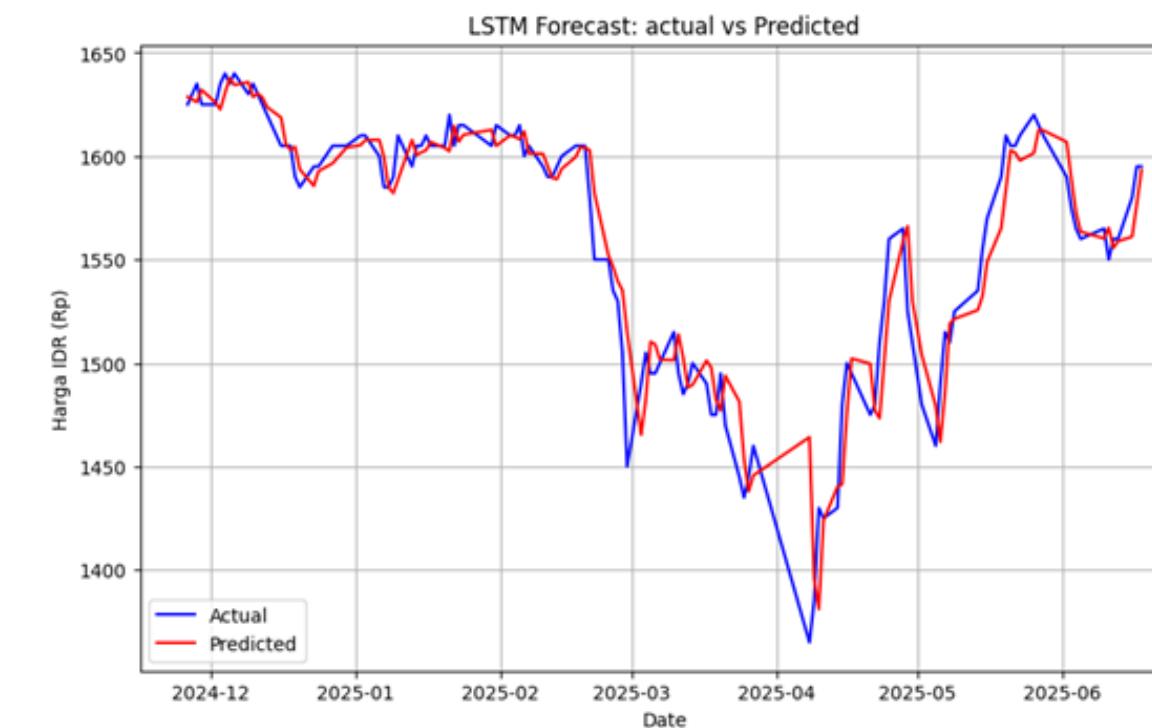


# Bab 4: Analisis Metode Nonlinier (LSTM)

Setelah dilakukan pengujian ke data testing didapatkan metrik evaluasi menggunakan Root Mean Square Error (RMSE), Mean Absolute Error (MAE), dan Mean Absolute Percentage Error dengan rincian sebagai berikut.

35/35	2s 45ms/step
Training Metrics:	
RMSE: 30.878	
MAE: 19.103	
MAPE: 1.472%	
4/4	0s 35ms/step
Test Metrics:	
RMSE: 18.775	
MAE: 12.917	
MAPE: 0.851%	

Nilai Error yang lebih kecil pada data training menunjukkan bahwa data mampu belajar dari data training dan mampu generalisasi dengan sangat baik. Nilai MAPE di bawah 2% sangat kecil menandakan prediksi model sangat akurat, baik di training maupun testing.

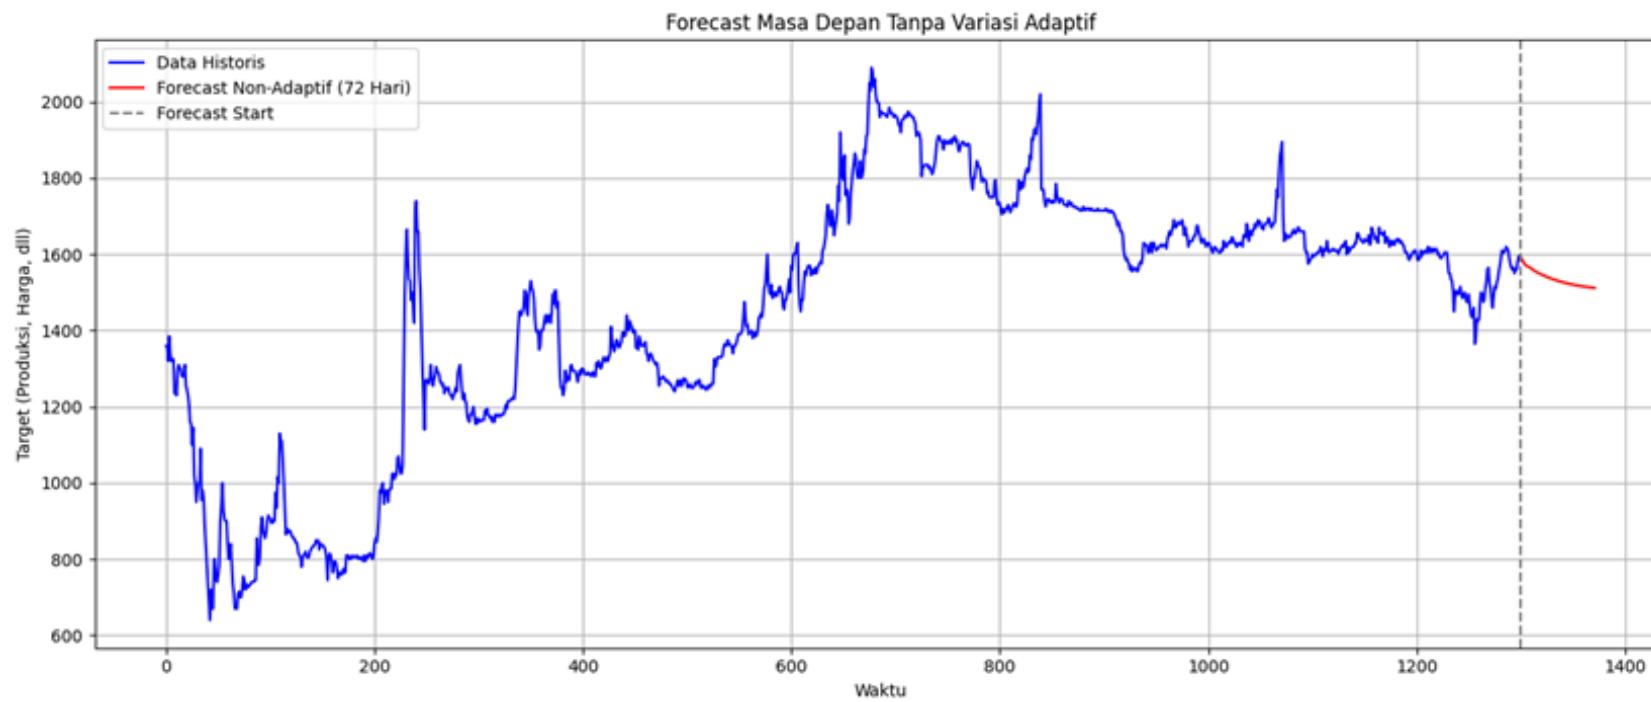


# Bab 4: Analisis Metode Nonlinier (LSTM)

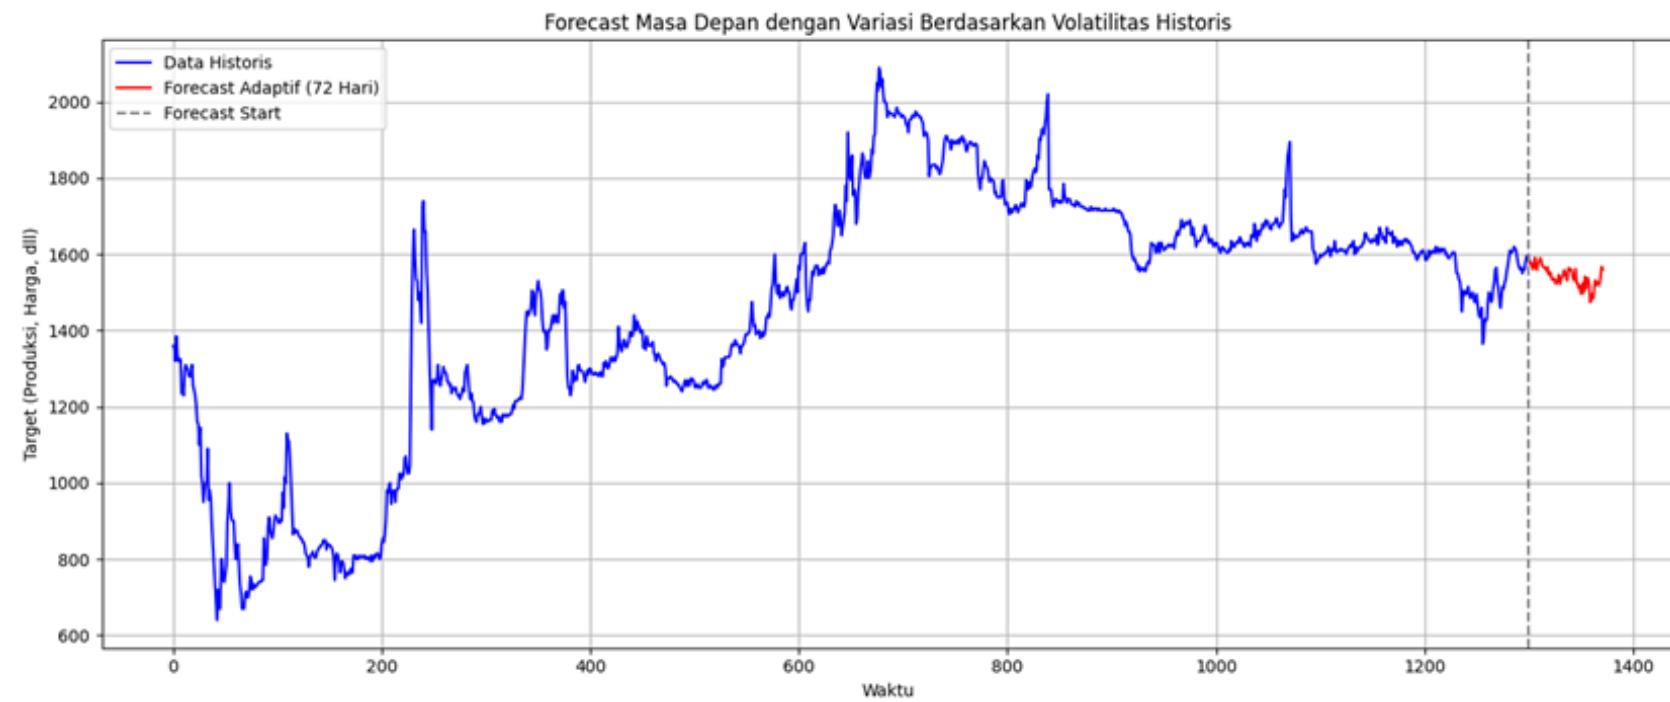
x

Untuk melihat apakah model LSTM masuk akal, maka dilakukan forecasting sebanyak 72 hari kedepan. dan didapatkan hasil sebagai berikut.

**Tanpa Mempertimbangkan Volatilitas**



**Mempertimbangkan Volatilitas**



Karena hasil LSTM yang terlalu smooth padahal realitanya harga saham cenderung volatil jadi dipertimbangkan untuk memberikan volatilitas kepada hasil forecast dan didapatkan hasil prediksi yang baik dan lebih akurat.

## Bab 4: Perbandingan Hasil Evaluasi Kedua Metode

x

Metrik utama yang digunakan untuk perbandingan pada penelitian ini adalah Mean Absolute Percentage Error (MAPE), karena metrik ini memberikan ukuran kesalahan prediksi dalam bentuk persentase, sehingga lebih mudah diinterpretasikan dan dibandingkan lintas skala. Disajikan perbandingan MAPE kedua model (ARIMA & LSTM) adalah sebagai berikut.

Model	MAPE (%)
ARIMA	0,649
LSTM	0,851

Didapatkan model ARIMA dalam evaluasi awal menunjukkan nilai MAPE yang lebih rendah, sedangkan hasil Long Short-Term Memory (LSTM) menunjukkan nilai MAPE yang lebih besar. Namun, model LSTM cenderung lebih unggul mengingat karakteristik nonlinier pada data harga penutupan harian PANS. Mengingat adanya parameter ARIMA yang tidak signifikan juga mengindikasikan adanya batasan atau kelemahan struktural model ARIMA tersebut dalam sepenuhnya menangkap kompleksitas sebenarnya dari data nonlinier.

## Bab 5: Penutup & Kesimpulan

Evaluasi terhadap model ARIMA dan LSTM dalam memprediksi data time series nonlinier menunjukkan bahwa meskipun ARIMA mungkin memiliki MAPE awal yang lebih rendah, keterbatasannya dalam menangkap pola nonlinier dan adanya parameter tidak signifikan mengindikasikan kelemahan strukturalnya. Sebaliknya, LSTM yang mampu mempelajari pola kompleks dan dependensi jangka panjang secara otomatis, lebih unggul secara strategis dan adaptif. Oleh karena itu, LSTM dinilai lebih robust dan prospektif untuk peramalan data nonlinier jangka panjang.

# TERIMA KASIH!